
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа Прикладной Математики и Информатики
Кафедра интеллектуальных систем

Направление подготовки / специальность: 03.03.01 Прикладные математика и физика

Направленность (профиль) подготовки: Математическая физика, компьютерные технологии и
математическое моделирование в экономике

АППРОКСИМАЦИИ ГРАДИЕНТА С ПОМОЩЬЮ ОРАКУЛА НУЛЕВОГО ПОРЯДКА И ТЕХНИКИ ЗАПОМИНАНИЯ

(бакалаврская работа)

Студент:

Богданов Александр Иванович

(подпись студента)

Научный руководитель:

Безносиков Александр Николаевич,
канд. физ.-мат. наук

(подпись научного руководителя)

Консультант (при наличии):

(подпись консультанта)

Москва 2024

Аннотация

В данной работе рассматривается проблема оптимизации «черного ящика». В такой постановке задачи нет доступа к градиенту целевой функции, поэтому его необходимо каким-либо образом оценить. Предлагается новый способ аппроксимации градиента **JAGUAR**, который запоминает информацию из предыдущих итераций и требует $\mathcal{O}(1)$ обращений к оракулу. Эта аппроксимация адаптирована для алгоритма Франка-Вульфа, в частности доказана сходимость для выпуклой постановки задачи. Анализируются как детерминированная постановка задачи минимизации, так и стохастическая на выпуклом ограниченном множестве Q с шумом в оракуле нулевого порядка, такая постановка довольно непопулярна в литературе. Но было доказано, что **JAGUAR** является робастной и в таком случае. Проведенные эксперименты показывают, что **JAGUAR** превосходит уже известные в литературе методы оценки градиента.

Содержание

1	Введение	4
2	Постановка задачи	8
2.1	Детерминированный случай	8
2.2	Стохастический случай	8
3	Основные результаты	10
3.1	Аппроксимация градиента JAGUAR	10
3.1.1	Использование JAGUAR	12
3.1.2	Анализ аппроксимаций JAGUAR	14
3.2	Применение JAGUAR в алгоритме Франка-Вульфа	15
3.2.1	Детерминированный случай	16
3.2.2	Стохастический случай	18
4	Вычислительный эксперимент	21
4.1	Постановка эксперимента	21
4.2	Детерминированный алгоритм Франка-Вульфа	22
4.3	Стохастический алгоритм Франка-Вульфа	23
5	Заключение	25
	Список литературы	26
	Приложение	34

1 Введение

Методы без проекций, в частности метод условного градиента, известный как алгоритм Франка-Вульфа [1], широко используются для решения различных задач оптимизации. В последнее десятилетие методы условного градиента вызывают все больший интерес в сообществе машинного обучения, поскольку во многих случаях вычислительно дешевле решить линейную задачу минимизации на подходящем выпуклом множестве (например, на l_p -шарах или симплексе Δ_d), чем сделать проекцию на него [2, 3, 4, 5, 6, 7, 8].

В оригинальной работе Франка-Вульфа [1] авторы использовали истинный градиент в своем алгоритме, однако современные задачи машинного обучения и искусственного интеллекта требуют использования различных оценок градиента, это связано со значительным увеличением размера датасетов и сложности современных моделей. Примерами таких градиентных оценок в алгоритмах типа Франка-Вульфа являются координатные методы [9, 10, 11] и стохастическая аппроксимация градиента по батчам [12, 13, 14].

Но иногда встречаются еще более сложные ситуации, когда нельзя вычислить градиент в общем случае, потому что он недоступен по разным причинам, например, целевая функция не дифференцируема или вычисление градиента вычислительно сложно [15, 16, 17, 18, 19]. Такая постановка называется оптимизацией «черного ящика» [20], и в этом случае необходимо использовать методы оценки градиента нулевого порядка через конечные разности целевой функции (иногда с дополнительным шумом) для аппроксимации градиента [21, 22].

За последние годы исследований по теме оптимизации «черного ящика» можно выделить два основных метода аппроксимации градиента с помощью конечных разностей. Первый оценивает градиент в m координатах [23, 24, 25]:

$$\frac{d}{m} \sum_{i \in I} \frac{f(x + \tau e_i) - f(x - \tau e_i)}{2\tau} e_i, \quad (1)$$

где $I \subset \overline{1, d} : |I| = m$, e_i – вектор из стандартного базиса в \mathbb{R}^d и τ – па-

параметр сглаживания. Эта конечная разность аппроксимирует градиент в m координатах и требует $\mathcal{O}(m)$ вызовов оракула. Если m мало, то такая оценка будет неточной, если m велико, то на каждой итерации нужно делать много обращений к оракулу нулевого порядка. В случае $m = d$ этот метод называется *полной аппроксимацией*.

Второй использует в конечной разности не стандартный базис, а случайные вектора e [17, 22, 26, 27]:

$$d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad (2)$$

где e может быть равномерно распределено на l_p -сфере $RS_p^d(1)$, тогда эта схема называется *l_p -сглаживание*. В последних работах авторы обычно используют $p = 1$ [28, 29] или $p = 2$ [30, 31, 32]. Кроме того, e может быть взято из нормального распределения с нулевым средним и единичной ковариационной матрицей [17].

Аппроксимации (1) и (2) имеют очень большую дисперсию или требуют большого количества обращений к нулевому оракулу, поэтому возникает необходимость как-то уменьшить ошибку аппроксимации, не увеличивая при этом количество обращений к нулевому оракулу. В стохастической оптимизации довольно широко используется метод запоминания информации с предыдущих итераций, например, в SVRG [33], SAGA [34], SARAH [35] и SEGA [36] авторы предлагают запоминать градиент с предыдущих итераций для лучшей сходимости метода. В данной работе используется эта техника в задаче оптимизации «черного ящика» и запоминаются аппроксимации градиента из предыдущих итераций для уменьшения размера батча без существенной потери точности. Ставятся следующие вопросы:

- *Можно ли создать метод нулевого порядка, который будет использовать информацию из предыдущих итераций и аппроксимировать истинный градиент так же точно, как и полная аппроксимация (1), но потребует $\mathcal{O}(1)$ вызовов оракула нулевого порядка?*
- *Можно ли реализовать этот метод аппроксимации в алгоритме*

Франка-Вульфа для детерминированных и стохастических постановок задач минимизации?

- *Является ли оценка сходимости этого метода лучше, чем для разностных схем (1) и (2)?*

В более реалистичной постановке оракул нулевого порядка возвращает зашумленное значение целевой функции, то есть выдает не $f(x)$, а $f(x) + \delta(x)$. В литературе рассматриваются различные виды шума $\delta(\cdot)$: он может быть стохастическим [26, 32, 37, 38] или детерминированным [39, 40, 41, 42, 43, 44]. Поэтому возникает еще один исследовательский вопрос:

- *Как различные типы шума влияют на теоретические гарантии и практические результаты для предложенных подходов?*

В соответствии с вопросами исследования, вклад может быть обобщен следующим образом:

- Представлен метод **JAGUAR**, который аппроксимирует истинный градиент целевой функции $\nabla f(x)$ в точке x . Использование памяти предыдущих итераций позволяет достичь точности, близкой к полной аппроксимации (1), но **JAGUAR** требует не $\mathcal{O}(d)$, а $\mathcal{O}(1)$ обращений к оракулу нулевого порядка. l_p -сглаживание (2) также требует $\mathcal{O}(1)$ обращения к оракулу, но поскольку в нем нет техники памяти, этот метод имеет большую дисперсию и не является робастным. (см. раздел 3.1)
- Аппроксимация **JAGUAR** внедрена в алгоритм Франка-Вульфа для стохастических и детерминированных задач минимизации и доказана сходимость в обоих случаях (см. раздел 3.2).
- Проведены вычислительные эксперименты сравнения аппроксимации **JAGUAR** с *полной аппроксимацией* (1) и l_2 -сглаживанием (2) на различных задачах минимизации (см. раздел 4).

В литературе некоторые авторы считают координатные методы [9] тоже градиентной аппроксимаций, но эти методы используют истинный градиент целевой функции f , поэтому ее нельзя напрямую применить к оптимизации «черного ящика».

Метод l_p -сглаживания не требует дифференцируемости целевой функции, поскольку рассматривает сглаженную версию функции f вида $f_\gamma(x) = \mathbb{E}_e [f(x + \gamma e)]$. В общем случае метод l_p -сглаживания может аппроксимировать градиент с помощью $\mathcal{O}(1)$ вызовов оракула [43], но он может быть не робастным в постановке Франка-Вульфа, поскольку в [45] авторам приходится собирать большой батч направлений e для достижения сходимости. Отмечается, что в [45] рассматривается детерминированный шум.

Полная аппроксимация также используется в литературе [46, 47, 48], но на каждой итерации необходимо делать $\mathcal{O}(d)$ вызовов оракула, а поскольку в современных приложениях d огромно, это может быть проблемой. Также этот метод требует гладкости целевой функции f .

В Таблице 1 приведено сравнение постановок задач, методов аппроксимации и результатов для них.

Метод	Постановка		Шум		Размер батча	Аппроксимация
	Гладкая	Нулевой порядок	Стохастический	Детерминированный		
ZO-SCGS [45]	✗	✓	✗	✓	$\mathcal{O}(1/\varepsilon^2)$	l_2 -сглаживание (2)
FZFW [47]	✓	✓	✗	✗	$\mathcal{O}(\sqrt{d})$	полная аппроксимация (1)
DZOFW [46]	✓	✓	✗	✗	$\mathcal{O}(d)$	полная аппроксимация (1)
MOST-FW [48]	✓	✓	✗	✗	$\mathcal{O}(d)$	полная аппроксимация (1)
BCFW [9]	✓	✗	✗	✗	$\mathcal{O}(1)$	координатный
SSFW [49]	✓	✗	✗	✗	$\mathcal{O}(1)$	координатный
FW с JAGUAR (эта работа)	✓	✓	✓	✓	$\mathcal{O}(1)$	JAGUAR (Алгоритмы 1 и 2)

Таблица 1: Сравнение различных методов нулевого порядка и координатных методов алгоритма Франка-Вульфа.

2 Постановка задачи

В данной работе рассматривается оптимизационная задача:

$$f(x^*) := \min_{x \in Q} f(x), \text{ где } Q \subseteq \mathbb{R}^d. \quad (3)$$

2.1 Детерминированный случай

Предполагается, что доступ есть только к оракулу нулевого порядка, и он возвращает зашумленное значение функции $f(x)$:

$$f_\delta(x) := f(x) + \delta(x).$$

На функцию и шум накладываются классические ограничения необходимые для анализа:

- Функция $f(x)$ L -гладкая на множестве Q , т.е.

$$\exists L > 0 : \forall x, y \in Q \hookrightarrow \|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|. \quad (4)$$

- Шум $\delta(x)$ оракула ограничен, т.е.

$$\exists \Delta > 0 : \forall x \in Q \hookrightarrow |\delta(x)|^2 \leq \Delta^2. \quad (5)$$

2.2 Стохастический случай

В этом разделе рассматривается стохастическая версия задачи (3):

$$f(x) := \mathbb{E}_{\xi \sim \pi} [f(x, \xi)], \quad (6)$$

где ξ – случайный вектор из обычно неизвестного распределения π .

Снова предполагается, что нет доступа к истинному значению градиента $\nabla f(x, \xi)$, и оракул нулевого порядка возвращает зашумленное значение функции $f(x, \xi)$:

$$f_\delta(x, \xi) := f(x, \xi) + \delta(x, \xi).$$

На функцию и шум также накладываются классические ограничения необходимые для анализа:

- Функция $f(x, \xi)$ $L(\xi)$ -гладкая на множестве Q , т.е.

$$\forall x, y \in Q \hookrightarrow \|\nabla f(x, \xi) - \nabla f(y, \xi)\| \leq L(\xi) \|x - y\|, \quad (7)$$

где $L^2 := \mathbb{E} [L(\xi)^2]$.

С учетом этого предположения, функция $f(x)$ является L -гладкой на множестве Q :

$$\begin{aligned} \forall x, y \in Q \hookrightarrow \|\nabla f(x) - \nabla f(y)\|^2 &= \|\mathbb{E} [\nabla f(x, \xi) - \nabla f(y, \xi)]\|^2 \\ &\leq \mathbb{E} [\|\nabla f(x, \xi) - \nabla f(y, \xi)\|^2] \\ &\leq L^2 \|x - y\|^2. \end{aligned}$$

- Шум оракула ограничен некоторой константой $\Delta > 0$, т.е.

$$\exists \Delta > 0 : \forall x \in Q \hookrightarrow \mathbb{E} [|\delta(x, \xi)|^2] \leq \Delta^2. \quad (8)$$

С учетом этого предположения, если определить $\delta(x) := \mathbb{E} [\delta(x, \xi)]$, то $|\delta(x)|^2 \leq \Delta^2$, так как $|\delta(x)|^2 = |\mathbb{E} [\delta(x, \xi)]|^2 \leq \mathbb{E} [|\delta(x, \xi)|^2] \leq \Delta^2$.

- Второй момент $\nabla f(x, \xi)$ ограничен, т.е.

$$\exists \sigma_{\nabla} \geq 0 : \forall x \in Q \hookrightarrow \mathbb{E} [\|\nabla f(x, \xi) - \nabla f(x)\|^2] \leq \sigma_{\nabla}^2. \quad (9)$$

- Второй момент $f(x, \xi)$ ограничен, т.е.

$$\exists \sigma_f \geq 0 : \forall x \in Q \hookrightarrow \mathbb{E} [|f(x, \xi) - f(x)|^2] \leq \sigma_f^2. \quad (10)$$

3 Основные результаты

3.1 Аппроксимация градиента JAGUAR

Выше были рассмотрены методы аппроксимации градиента с помощью конечных разностей (1) и (2). В этом разделе представлены новые методы оценки градиента JAGUAR: JAGUAR-d для детерминированной и JAGUAR-s для стохастической задач, основанные на уже исследованных методах и использующие память предыдущих итераций.

Идея метода JAGUAR схожа с известными методами уменьшения дисперсии, такими как SAGA [34] или SVRG [33], но эти методы используют данную технику к батчам. Однако при оптимизации нулевого порядка нужно аппроксимировать градиент, поэтому необходимо применить технику уменьшения дисперсии к координатам [36]. Метод JAGUAR использует память некоторых координат предыдущих градиентов, а не запоминает градиенты по батчам в прошлых точках. В литературе уже есть работы, сочетающие оптимизацию нулевого порядка и уменьшение дисперсии, но суть их в том, что они меняют вычисление градиента на безградиентную аппроксимацию (1) в пакетных алгоритмах с уменьшением дисперсии, таких как SVRG или SPIDER [50], а не используют технику уменьшения дисперсии для координат, как в алгоритме 1.

Для детерминированного алгоритма аппроксимации используется разностная схема:

$$\tilde{\nabla}_i f_\delta(x) := \frac{f_\delta(x + \tau e_i) - f_\delta(x - \tau e_i)}{2\tau} e_i, \quad (11)$$

где e_i – вектор из стандартного базиса в \mathbb{R}^d . Также введем обозначение, которое потребуется для анализа:

$$\tilde{\nabla} f_\delta(x) := \sum_{i=1}^d \frac{f_\delta(x + \tau e_i) - f_\delta(x - \tau e_i)}{2\tau} e_i.$$

Сам алгоритм аппроксимации градиента для детерминированной задачи JAGUAR-d в точке x выглядит следующим образом (алгоритм 1):

Алгоритм 1 JAGUAR-d

- 1: **Вход:** $x \in Q$; $h \in \mathbb{R}^d$; $\tau \in \mathbb{R}$
 - 2: Сэмплируем $i \in \overline{1, d}$ равномерно и независимо
 - 3: Считаем $\tilde{\nabla}_i f_\delta(x) = \frac{f_\delta(x + \tau e_i) - f_\delta(x - \tau e_i)}{2\tau} e_i$
 - 4: $h = h - \langle h, e_i \rangle e_i + \tilde{\nabla}_i f_\delta(x)$
 - 5: **Выход:** h
-

В стохастической постановке (3) + (6) есть две версии разностных схем (11). Первая называется двухточечной обратной связью (ДОС) [26, 31, 32, 51, 52], в данном случае аппроксимация градиента функции $f(x, \xi)$:

$$\tilde{\nabla}_i f_\delta(x, \xi) := \frac{f_\delta(x + \tau e_i, \xi) - f_\delta(x - \tau e_i, \xi)}{2\tau} e_i. \quad (12)$$

Вторая называется однотоечной обратной связью (ООС) [30, 38, 53, 54, 55], в этом случае аппроксимация градиента функции $f(x, \xi)$:

$$\tilde{\nabla}_i f_\delta(x, \xi^\pm) := \frac{f_\delta(x + \tau e_i, \xi^+) - f_\delta(x - \tau e_i, \xi^-)}{2\tau} e_i. \quad (13)$$

Для дальнейшего упрощения выкладок считается, что в случае двухточечной обратной связи (12) $\xi^+ = \xi^- = \xi$. Ключевое различие между приближениями (12) и (13) заключается в том, что схема (12) более точна, но ее сложно реализовать на практике, так как для этого необходимо получить одну и ту же реализацию ξ в двух разных точках $x + \tau e$ и $x - \tau e$, поэтому схема (13) более интересна с практической точки зрения. Введем обозначение, которое потребуется для дальнейшего анализа:

$$\tilde{\nabla} f_\delta \left(x, \xi_{1,d}^\pm \right) := \sum_{i=1}^d \frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} e_i.$$

Алгоритм аппроксимации градиента для стохастической задачи JAGUAR-s в точке x представлен ниже (алгоритм 2):

Алгоритм 2 JAGUAR-s

- 1: **Вход:** $x \in Q$; $h, g \in \mathbb{R}^d$; $\tau \in \mathbb{R}$; $\eta \in [0, 1]$
 - 2: Сэмплируем $i \in \overline{1, d}$ равномерно и независимо
 - 3: Сэмплируем ξ : ξ^+ и ξ^- независимо (в случае ДОС $\xi^+ = \xi^-$)
 - 4: Считаем $\tilde{\nabla}_i f_\delta(x, \xi^\pm) = \frac{f_\delta(x + \tau e_i, \xi^+) - f_\delta(x - \tau e_i, \xi^-)}{2\tau} e_i$
 - 5: $\rho = h - d \cdot \langle h, e_i \rangle e_i + d \cdot \tilde{\nabla}_i f_\delta(x, \xi^+, \xi^-)$
 - 6: $h = h - \langle h, e_i \rangle e_i + \tilde{\nabla}_i f_\delta(x, \xi^+, \xi^-)$
 - 7: $g = (1 - \eta)g + \eta\rho$
 - 8: **Выход:** g, h
-

Алгоритм JAGUAR-s (алгоритм 2) аналогичен JAGUAR-d (алгоритм 1), но в строках 5 и 7 используются части SEGA [36] и моментума [56] для сходимости в стохастическом случае.

В JAGUAR-s необходима часть SEGA [36] ρ , поскольку важно свойство «несмещенности» (см. доказательство Леммы 4). Ее использование ухудшает оценки в d раз по сравнению с использованием h в качестве градиентной аппроксимации (см. Леммы 2 и 3).

В JAGUAR-s необходим моментум [56] η , поскольку при оценке выражения $\mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x, \xi_{1,d}^\pm) - \nabla f(x) \right\|^2 \right]$ в стохастическом случае появляются выражения, содержащие $\sigma_{\tilde{\nabla}}^2$ и σ_f^2 , и они мешают сходимости (см. Лемму 1).

3.1.1 Использование JAGUAR

Алгоритм аппроксимации градиента JAGUAR-d может быть использован с любыми итерационными схемами, которые на каждом шаге k возвращают новую точку x^k . Используя эти точки, получается последовательность h^k , которая в некотором смысле служит памятью компонент градиента из прошлых моментов. Поэтому в методах инкрементальной оптимизации имеет смысл использовать h^k в качестве оценки истинного градиента $\nabla f(x^k)$. Используя следующую унифицированную схему, можно описать такой итерационный

алгоритм, решающий задачу (3) (алгоритм 3):

Алгоритм 3 Итерационный алгоритм с использованием JAGUAR-d

```

1: Вход: Proc;  $x^0 \in Q$ ;  $h^0 \in \mathbb{R}^d$ ;  $\tau \in \mathbb{R}$ 
2: for  $k = 0, 1, 2, \dots, N$  do
3:    $h^{k+1} = \text{JAGUAR-d}(x^k, h^k, \tau)$ 
4:    $x^{k+1} = \text{Proc}(x^k, \text{grad\_est} = h^{k+1})$ 
5: end for
6: Выход:  $x^{N+1}$ 

```

Использование алгоритма аппроксимации JAGUAR-s похоже на использование алгоритма JAGUAR-d, но в качестве оценки градиента используется g^k . Итерационный алгоритм, решающий задачу (3) + (6) представлен ниже (алгоритм 4):

Алгоритм 4 Итерационный алгоритм с использованием JAGUAR-s

```

1: Вход: Proc;  $x^0 \in Q$ ;  $h^0, g^0 \in \mathbb{R}^d$ ;  $\tau \in \mathbb{R}$ ;  $\eta_k \in [0, 1]$ 
2: for  $k = 0, 1, 2, \dots, N$  do
3:    $h^{k+1}, g^{k+1} = \text{JAGUAR-s}(x^k, h^k, g^k, \tau, \eta_k)$ 
4:    $x^{k+1} = \text{Proc}(x^k, \text{grad\_est} = g^{k+1})$ 
5: end for
6: Выход:  $x^{N+1}$ 

```

В алгоритмах 3 и 4, $\text{Proc}(x^k, \text{grad_est})$ – это некоторая последовательность действий, которая переводит x^k в x^{k+1} , используя grad_est в качестве истинного градиента. В следующем разделе приведен анализ аппроксимации градиента JAGUAR.

3.1.2 Анализ аппроксимаций JAGUAR

В данном параграфе приведены леммы для анализа аппроксимаций градиента JAGUAR. Леммы 1 и 2 нужны и для детерминированного случая, и для стохастического. Чтобы применить эти леммы в случае двухточечной обратной связи (12), не нужно предположение 10. В этом случае $\sigma_f = 0$. Чтобы применить эти леммы для детерминированного случая, предположения 9 и 10 не нужны. А вместо предположений 7 и 8 нужно использовать аналогичные предположения для детерминированного случая 4 и 5. Помимо этого нужно сделать замену $\tilde{\nabla} f_\delta(x, \xi_{1,d}^\pm)$ на $\tilde{\nabla} f_\delta(x)$. В этом случае $\sigma_\nabla = \sigma_f = 0$. Кроме этого в доказательствах лемм встретится сокращение:

$$\tilde{\nabla} f_\delta(x, \xi^\pm) := \sum_{i=1}^d \frac{f_\delta(x + \tau e_i, \xi^+) - f_\delta(x - \tau e_i, \xi^-)}{2\tau} e_i.$$

Лемма 1. *При предположениях 7, 8, 9 и 10 в случае одноточечной обратной связи (13) выполняется следующее неравенство:*

$$\mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x, \xi_{1,d}^\pm) - \nabla f(x) \right\|^2 \right] \leq d \left(L^2 \tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_\nabla^2 + \frac{2\Delta^2}{\tau^2} \right).$$

Доказательство приведено в Приложении В.1.

Лемма 2. *При предположениях 7, 8, 9 и 10 в случае одноточечной обратной связи (13) выполняется следующее неравенство:*

$$\begin{aligned} \mathbb{E} \left[\|h^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq \left(1 - \frac{1}{2d} \right) \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \\ &\quad + 2dL^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \\ &\quad + L^2 \tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_\nabla^2 + \frac{2\Delta^2}{\tau^2}. \end{aligned}$$

Доказательство приведено в Приложении В.2.

Леммы 3 и 4 нужны только для стохастического случая. Чтобы применить эти леммы в случае двухточечной обратной связи (12), не нужно предположение 10. В этом случае $\sigma_f = 0$.

Лемма 3. При предположениях 7, 8, 9 и 10 в случае односточечной обратной связи (13) выполняется следующее неравенство:

$$\begin{aligned}\mathbb{E} \left[\|\rho^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq 4d\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \\ &\quad + 2dL^2\mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \\ &\quad + 4d^2 \left(L^2\tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_{\nabla}^2 + \frac{2\Delta^2}{\tau^2} \right).\end{aligned}$$

Доказательство приведено в Приложении В.3.

Лемма 4. При предположениях 7, 8, 9 и 10 в случае односточечной обратной связи (13) выполняется следующее неравенство:

$$\begin{aligned}\mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq (1 - \eta_k) \mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] \\ &\quad + \eta_k^2 \mathbb{E} \left[\|\rho^{k+1} - \nabla f(x^{k+1})\|^2 \right] \\ &\quad + \frac{4L^2}{\eta_k} \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \\ &\quad + 3\eta_k d \left(L^2\tau^2 + \frac{2\Delta^2}{\tau^2} \right).\end{aligned}$$

Доказательство приведено в Приложении В.4.

3.2 Применение JAGUAR в алгоритме Франка-Вульфа

В данном разделе рассматривается применение алгоритма аппроксимации к алгоритму Франка-Вульфа (алгоритм 5):

Алгоритм 5 Алгоритм Франка-Вульфа

- 1: **Вход:** $x_0 \in Q$, γ_k
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $s^k = \arg \min_{s \in Q} \langle s, \nabla f(x^k) \rangle$
 - 4: $x^{k+1} = x^k + \gamma_k(s^k - x^k)$
 - 5: **end for**
 - 6: **Выход:** x^{N+1}
-

На множество Q накладываются необходимые ограничения, без которых алгоритм Франка-Вульфа не работает:

- Множество Q – компактное, т.е.

$$\exists D > 0 : \forall x, y \in Q \hookrightarrow \|x - y\| \leq D \quad (14)$$

- Множество Q – выпуклое, т.е.

$$\forall 0 \leq \alpha \leq 1, \forall x, y \in Q \hookrightarrow \alpha x + (1 - \alpha)y \in Q \quad (15)$$

Анализ применения **JAGUAR** в алгоритме Франка-Вульфа проводится для случая выпуклой на множестве Q функции $f(x)$, т.е.

$$\forall x, y \in Q \hookrightarrow f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle. \quad (16)$$

В следующих разделах рассмотрены детерминированные и стохастические алгоритмы Франка-Вульфа с использованием аппроксимации градиента **JAGUAR**.

3.2.1 Детерминированный случай

В этом разделе представляется алгоритм Франка-Вульфа, который решает задачу (3) с помощью аппроксимации градиента **JAGUAR** (алгоритм 6).

Алгоритм 6 Детерминированный алгоритм Франка-Вульфа с **JAGUAR**

- 1: **Вход:** $x^0 \in Q$, $h^0 = \tilde{\nabla} f_\delta(x^0)$, γ_k , τ
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $h^{k+1} = \text{JAGUAR-d}(x^k, h^k, \tau)$
 - 4: $s^k = \arg \min_{x \in Q} \langle s, h^{k+1} \rangle$
 - 5: $x^{k+1} = x^k + \gamma_k(s^k - x^k)$
 - 6: **end for**
 - 7: **Выход:** x^{N+1}
-

Используя заданную форму функции `Proc` в алгоритме 6, можно нужным образом подобрать шаг γ_k .

Теорема 1 (Богданов А., Подбор шага для детерминированного алгоритма Франка-Вульфа с JAGUAR). *При предположениях 4, 5 и 14 для h^k , полученного алгоритмом 6, можно взять*

$$\gamma_k = \frac{4}{k + 8d},$$

тогда выполняется следующая оценка:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2 \max \left\{ L^2 D^2, \|h^0 - \nabla f(x^0)\|^2 \right\}}{(k + 8d)^2} + dL^2 \tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Если дополнительно $h^0 = \tilde{\nabla} f_\delta(x^0)$, то можно упростить:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2 L^2 D^2}{(k + 8d)^2} + dL^2 \tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Доказательство приведено в Приложении С.1.

Теорема 2 (Богданов А., Скорость сходимости детерминированного алгоритма Франка-Вульфа с JAGUAR). *При предположениях 4, 5, 14, 15, и 16 можно взять*

$$\gamma_k = \frac{4}{k + 8d},$$

тогда алгоритм Франка-Вульфа с JAGUAR (алгоритм 6) имеет следующую скорость сходимости:

$$\mathbb{E} [f(x^k) - f(x^*)] = \mathcal{O} \left(\frac{d \max \{ LD^2, f(x^0) - f(x^*) \}}{k + 8d} + \sqrt{d} LD \tau + \frac{\sqrt{d} \Delta D}{\tau} \right).$$

Доказательство приведено в Приложении С.2.

Следствие 1. В соответствии с условиями теоремы 2, выбирая γ_k, τ, Δ как

$$\gamma_k = \frac{4}{k + 8d}, \tau = \mathcal{O} \left(\frac{\varepsilon}{\sqrt{d} LD} \right), \Delta = \mathcal{O} \left(\frac{\varepsilon^2}{dLD^2} \right),$$

чтобы получить ε -приближенное решение ($\mathbb{E} [f(x^k) - f(x^*)] \leq \varepsilon$) необходимо

$$\mathcal{O} \left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{\varepsilon} \right) \text{ итераций.}$$

Результаты Теоремы 2 совпадают с результатами [1, 57], в которых авторы использовали истинный градиент и получили результат вида $\mathbb{E} [f(x^N) - f(x^*)] = \mathcal{O} (\max\{LD^2; f(x^0) - f(x^*)\}/N)$. В случае нулевого порядка неизбежно появляются члены вида $\mathcal{O} (\text{poly}(\tau) + \text{poly}(\Delta/\tau))$, поскольку они имеют решающее значение для аппроксимации истинного градиента и всегда влияют на сходимость методов нулевого порядка [39, 41, 58, 59]. Фактор d , который появляется в теоретических оценках по сравнению с результатом первого порядка, связан со структурой метода нулевого порядка.

3.2.2 Стохастический случай

В этом разделе рассматривается алгоритм Франка-Вульфа, который решает задачу (3) + (6) с помощью аппроксимации градиента JAGUAR (алгоритм 2).

Алгоритм 7 Стохастический алгоритм Франка-Вульфа с JAGUAR

- 1: **Вход:** $x^0 \in Q$, $h^0 = g^0 = \tilde{\nabla} f_\delta(x^0)$, γ_k , η_k , τ
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $g^{k+1}, h^{k+1} = \text{JAGUAR-s} (x^k, h^k, g^k, \tau, \eta_k)$
 - 4: $s^k = \arg \min_{x \in Q} \langle s, g^{k+1} \rangle$
 - 5: $x^{k+1} = x^k + \gamma_k (s^k - x^k)$
 - 6: **end for**
 - 7: **Выход:** x^{N+1}
-

Можно получить теорему, аналогичную Теореме 1, если нужным образом подобрать шаг γ_k и шаг моментума η_k .

Теорема 3 (Богданов А., Подбор шага для стохастического алгоритма Франка–Вульфа с JAGUAR). *При предположениях 7, 8, 9, 10 и 14 в случае одноточечной обратной связи для g^k , полученного алгоритмом 7, можно взять*

$$\gamma_k = \frac{4}{k + 8d^{3/2}} \quad \text{и} \quad \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}},$$

тогда выполняется следующая оценка:

$$\mathbb{E} [\|g^k - \nabla f(x^k)\|^2] = \mathcal{O} \left(\frac{\max \left\{ L^2 D^2 + d^2 \sigma_f^2 / \tau^2 + d^2 \sigma_{\nabla}^2, d \mathbb{E} [\|g^0 - \nabla f(x^0)\|^2] \right\}}{(k + 8d^{3/2})^{2/3}} + \frac{d^4 \mathbb{E} [\|h^0 - \nabla f(x^0)\|^2]}{(k + 8d^{3/2})^{8/3}} + dL^2 \tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Если дополнительно $h^0 = g^0 = \tilde{\nabla} f_{\delta} (x^0, \xi_{1,d}^{\pm})$, то можно упростить:

$$\mathbb{E} [\|g^k - \nabla f(x^k)\|^2] = \mathcal{O} \left(\frac{L^2 D^2 + d^2 \sigma_f^2 / \tau^2 + d^2 \sigma_{\nabla}^2}{(k + 8d^{3/2})^{2/3}} + dL^2 \tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

В случае двухточечной обратной связи не нужно предположение 10 и $\sigma_f = 0$. Доказательство приведено в Приложении С.3.

Полученная оценка хуже по сравнению с детерминированным случаем в Теореме 1, поскольку рассматривается более сложная постановка.

Теорема 4 (Богданов А., Скорость сходимости стохастического алгоритма Франка–Вульфа с JAGUAR). *При предположениях 7, 8, 9, 10, 14, 15 и 16 в случае одноточечной обратной связи можно взять:*

$$\gamma_k = \frac{4}{k + 8d^{3/2}} \quad \text{и} \quad \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}},$$

тогда алгоритм Франка–Вульфа с JAGUAR (Алгоритм 7) имеет следующую скорость сходимости:

$$\mathbb{E} [f(x^k) - f(x^*)] = \mathcal{O} \left(\frac{\max \{ LD^2 + d\sigma_f D / \tau + d\sigma_{\nabla} D, \sqrt{d}(f(x^0) - f(x^*)) \}}{(k + 8d^{3/2})^{1/3}} + \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau} \right).$$

В случае двухточечной обратной связи не нужно предположение 10 и $\sigma_f = 0$. Доказательство приведено в Приложении С.4.

Следствие 2. В соответствии с условиями теоремы 4, выбирая $\gamma_k, \eta_k, \tau, \Delta$ как

$$\gamma_k = \frac{4}{k + 8d^{3/2}}, \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}}, \tau = \mathcal{O}\left(\frac{\varepsilon}{\sqrt{d}LD}\right), \Delta = \mathcal{O}\left(\frac{\varepsilon^2}{dLD^2}\right),$$

чтобы получить ε -приближенное решение ($\mathbb{E}[f(x^N) - f(x^*)] \leq \varepsilon$) необходимо

$$\mathcal{O}\left(\max\left\{\left[\frac{\max\{LD^2 + d\sigma_{\nabla}D, \sqrt{d}(f(x^0) - f(x^*))\}}{\varepsilon}\right]^3; \frac{d^{9/2}\sigma_f^3L^3D^6}{\varepsilon^6}\right\}\right) \text{ итераций.}$$

В случае двухточечной обратной связи $\sigma_f = 0$ последнее выражение принимает вид

$$\mathcal{O}\left(\left[\frac{\max\{LD^2 + d\sigma_{\nabla}D, \sqrt{d}(f(x^0) - f(x^*))\}}{\varepsilon}\right]^3\right) \text{ итераций.}$$

Поскольку в алгоритме аппроксимации JAGUAR-s (алгоритм 2) использовались части SEGA и импульса, то не получается той же скорости сходимости, что и в теоремах 1 и 2 даже при переходе от стохастических к детерминированным настройкам, т.е. при задании $\sigma_{\Delta} = \sigma_f = 0$ в теоремах 1 и 2. Те же проблемы возникают и в случае первого порядка [13, 56], это связано с трудностями реализации стохастического градиента в алгоритмах типа Франка-Вульфа.

Можно применить JAGUAR-d (алгоритм 1) к стохастической задаче (3) + (6) и получить те же оценки, что и в Теоремах 1 и 2, только сглаженный член вида $\mathcal{O}(\text{poly}(\tau) + \text{poly}(\Delta/\tau))$ будет содержать слагаемые вида $\mathcal{O}(\text{poly}(\sigma_{\Delta}^2) + \text{poly}(\sigma_f^2/\tau))$. Поэтому, если $\sigma_{\Delta}^2, \sigma_f^2 \sim \Delta$, то детерминированный алгоритм 1 подходит для стохастической задачи (3) + (6). Однако это означает, что нужно использовать большие батчи, поэтому необходимо использовать SEGA и импульсные части в JAGUAR-s аппроксимации.

4 Вычислительный эксперимент

В этом разделе представлены результаты экспериментов по применению аппроксимации нулевого порядка JAGUAR к различным задачам оптимизации «черного ящика». Результаты включают детерминированный и стохастический случаи алгоритма Франка-Вульфа.

4.1 Постановка эксперимента

Рассматривается модель LogReg на множестве Q вида:

$$\min_{w \in Q} \left\{ f(w) = \frac{1}{m} \sum_{k=1}^m \log(1 + \exp[-y_k(Xw)_k]) + \frac{1}{2C} \|w\|^2 \right\}.$$

Также рассматривается модель SVM на множестве Q вида:

$$\min_{w \in Q, b \in \mathbb{R}} \left\{ f(w, b) = \frac{1}{m} \sum_{k=1}^m (1 - y_k[(Xw)_k - b])_+ + \frac{1}{2C} \|w\|^2 \right\}.$$

А также рассматривается модель Reg на множестве Q вида:

$$\min_{w \in Q} \{ f(w) = w^T A w + b^T w + c \}.$$

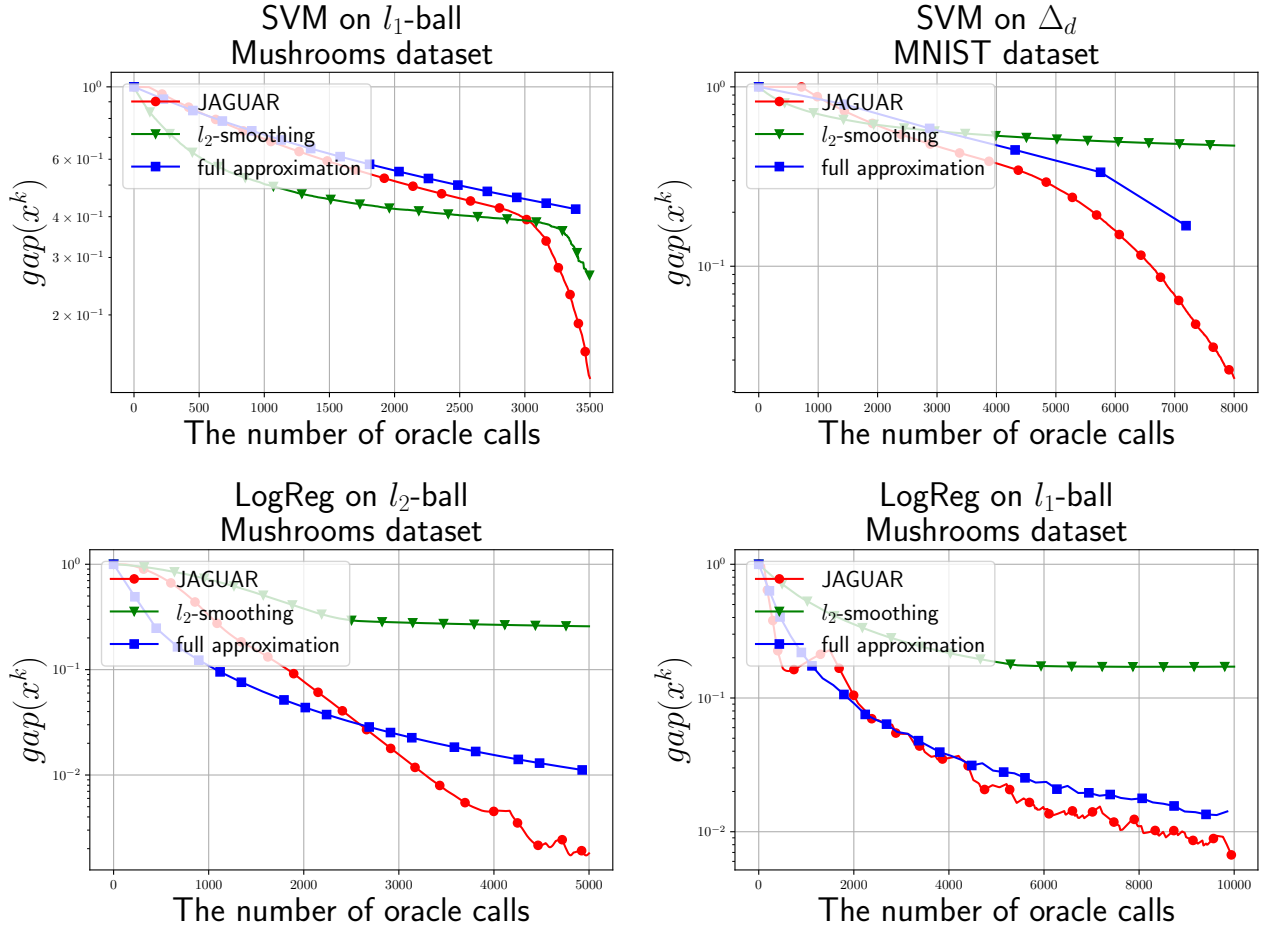
В задачах LogReg и SVM используются классические датасеты MNIST [60] и Mushrooms [61] и $C = 10$, а в задаче Reg используются синтетически сгенерированные данные. В качестве минимизирующего множества Q рассматриваются симплекс Δ_d , l_1 -шар и l_2 -шар. Метрикой качества будет значение $gap(x^k)$, которое обычно используется для алгоритма Франка-Вульфа:

$$gap(x^k) = \max_{y \in Q} \langle \nabla f(x^k), x^k - y \rangle$$

В эксперименте сравниваются различные методы аппроксимации. В качестве базовых оценок градиента рассматриваются l_2 -сглаживание (2) и полная аппроксимация (1). Показывается, что алгоритмы, использующие аппроксимацию JAGUAR (алгоритмы 1 и 2), работает лучше всего.

4.2 Детерминированный алгоритм Франка-Вульфа

В этом разделе рассматривается детерминированный шум вида $f_\delta(x) = \text{round}(f(x), 5)$, т.е. округление значения функции f до пятого знака после запятой. На Рисунке 1 показана сходимость детерминированного алгоритма Франка-Вульфа с аппроксимацией нулевого порядка. У алгоритм Франка-Вульфа с JAGUAR (алгоритм 6) результаты лучше, чем у базовых алгоритмов. Это наблюдение подтверждают теоретические выводы.



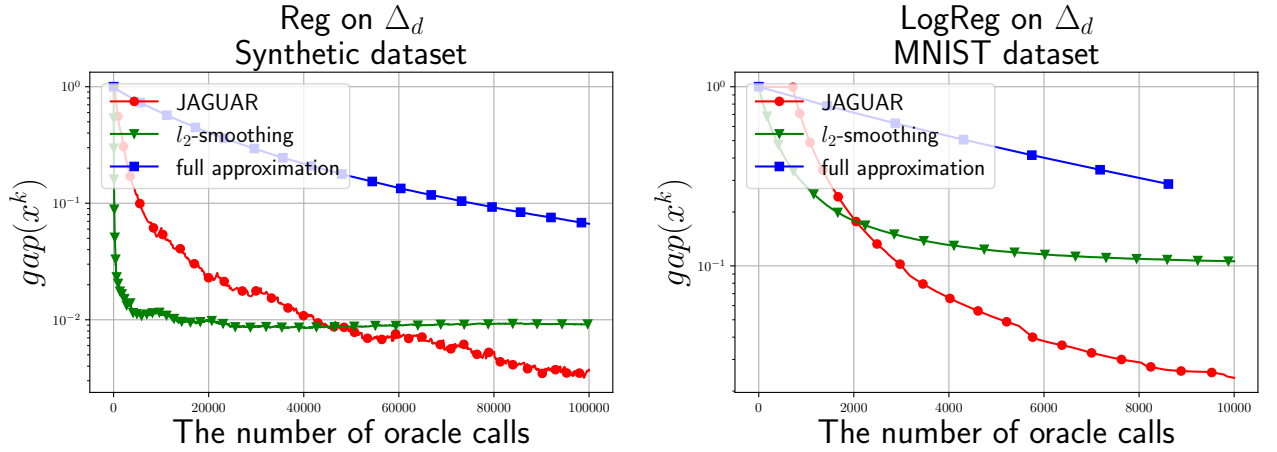


Рис. 1: Детерминированный алгоритм Франка-Вульфа.

4.3 Стохастический алгоритм Франка-Вульфа

В этом разделе рассматривается стохастический шум вида $f_\delta(x, \xi) = f(x) + \xi^T x$; $\xi_i = clip(\tilde{\xi}_i, -1, 1)$, $\tilde{\xi}_i \sim \mathcal{N}(0, 1)$, т. е. случайная величина сначала генерируется из стандартного нормального распределения, затем обрезается. На Рисунке 2 показана сходимость стохастического алгоритма Франка-Вульфа с аппроксимацией нулевого порядка в случае одноточечной обратной связи, а на Рисунке 3 в случае двухточечной обратной связи. Теоретические выводы подтверждаются наблюдениями. Алгоритм Франка-Вульфа с JAGUAR (алгоритм 7) устойчив к шуму и превосходит базовые алгоритмы.

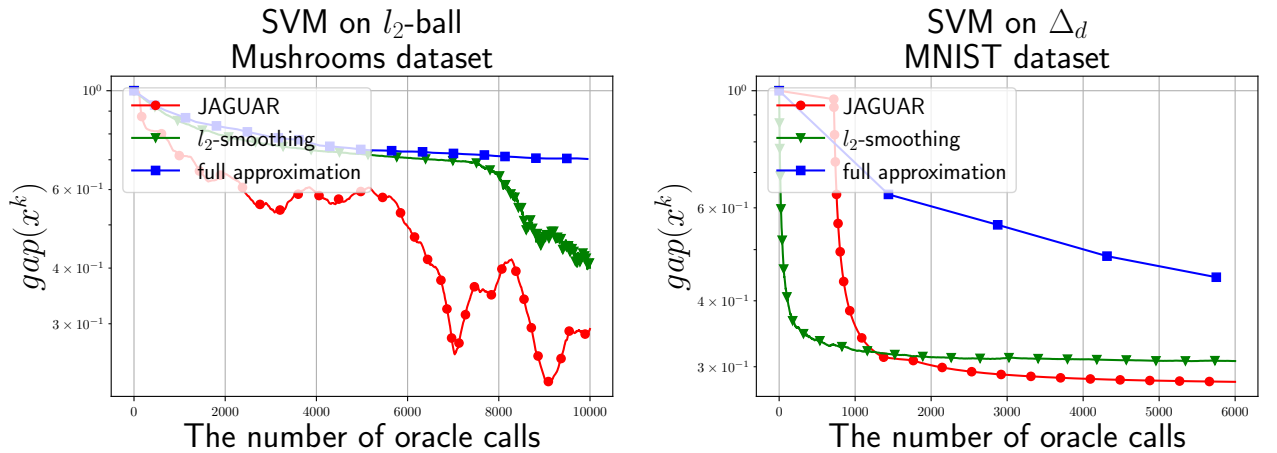


Рис. 2: Стохастический алгоритм (ООС) Франка-Вульфа.

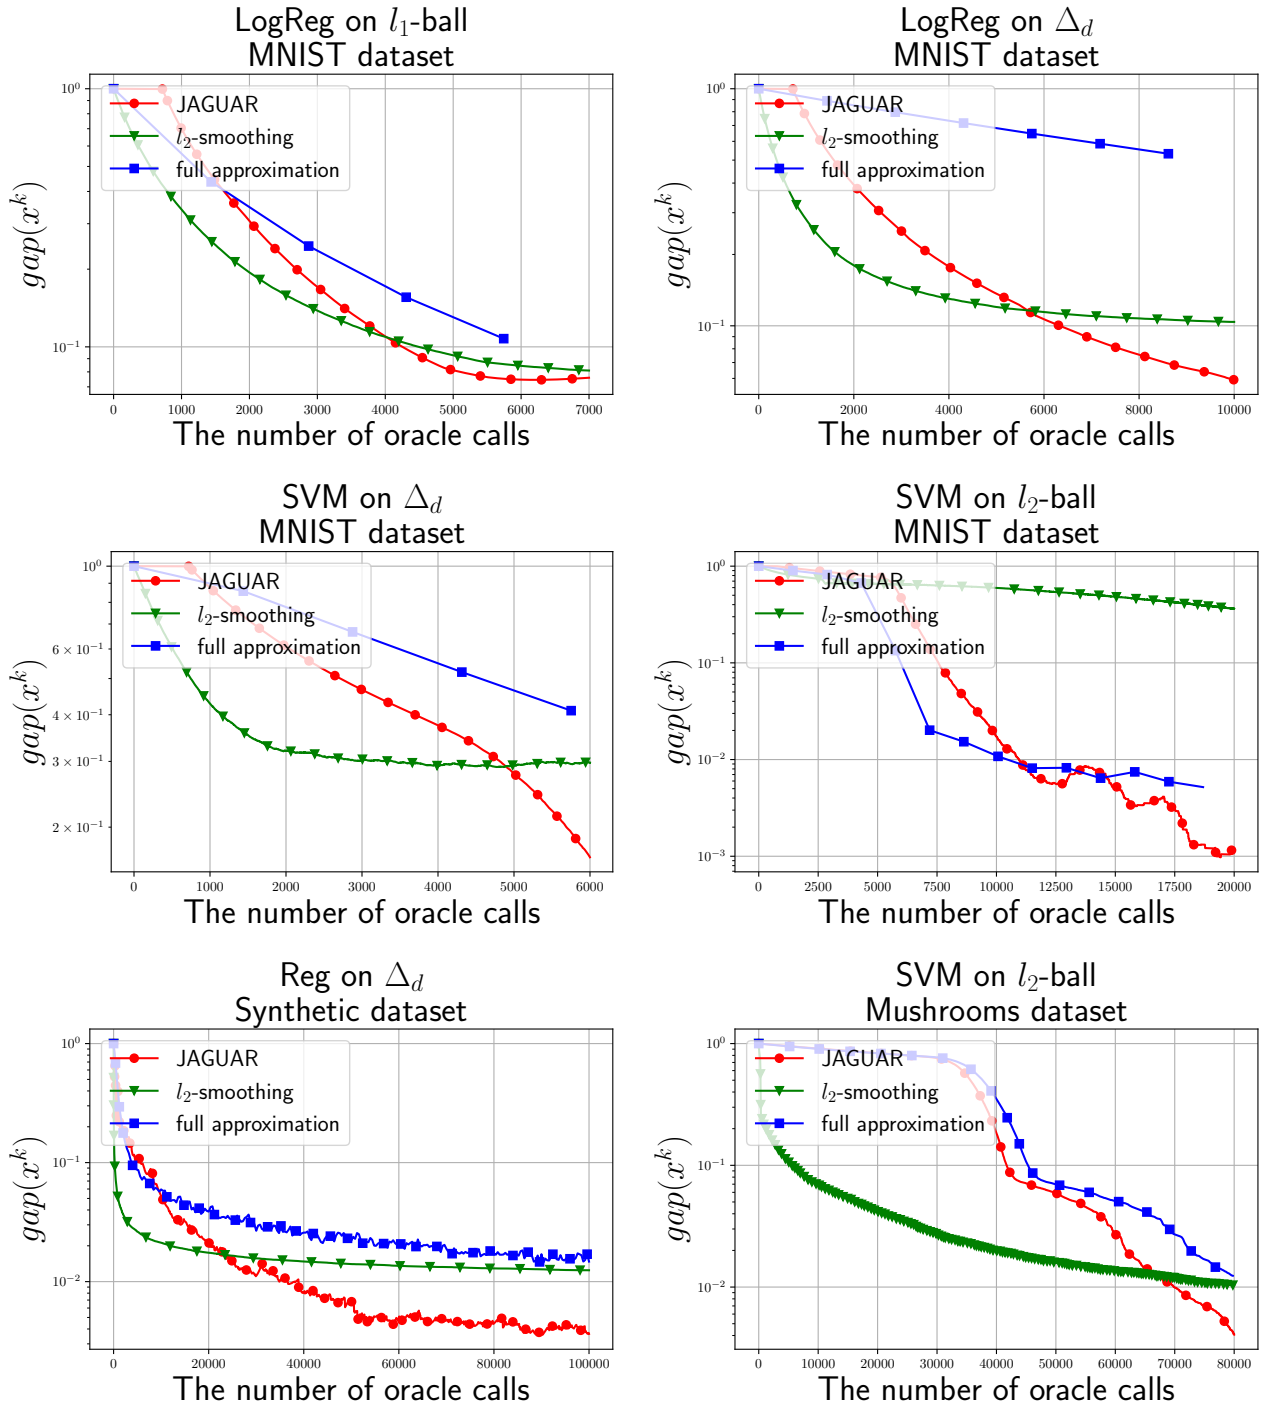


Рис. 3: Стохастический алгоритм (ДОС) Франка-Вульфа.

Код экспериментов можно посмотреть по репозитории <https://github.com/intsystems/Bogdanov-BS-Thesis/tree/main>.

Дополнительные эксперименты можно посмотреть в Приложении С.5.

5 Заключение

В данной работе представлен алгоритм **JAGUAR** - новый метод аппроксимации градиента, разработанный для решения задач оптимизации «черного ящика», использующий память о предыдущих итерациях для оценки истинного градиента с высокой точностью, требуя при этом всего $\mathcal{O}(1)$ вызовов оракула. Исследование содержит строгие теоретические доказательства и обширную экспериментальную проверку, демонстрируя превосходную производительность алгоритма **JAGUAR** как в детерминированных, так и в стохастических условиях. Ключевым вкладом является доказательство теорем для алгоритма Франка-Вульфа устанавливающих скорость сходимости. Экспериментальные результаты показывают, что **JAGUAR** превосходит базовые методы в задачах оптимизации SVM, LogReg и Reg. Полученные результаты подчеркивают эффективность и точность **JAGUAR**, что делает его перспективным подходом для будущих исследований и приложений в области оптимизации нулевого порядка.

Список литературы

- [1] Marguerite Frank and Philip Wolfe. An algorithm for quadratic programming. *Naval research logistics quarterly*, 3(1-2):95–110, 1956.
- [2] Larry J LeBlanc, Richard V Helgason, and David E Boyce. Improved efficiency of the frank-wolfe algorithm for convex network programs. *Transportation Science*, 19(4):445–462, 1985.
- [3] Martin Jaggi. Sparse convex optimization methods for machine learning. 2011.
- [4] Sébastien Bubeck et al. Convex optimization: Algorithms and complexity. *Foundations and Trends® in Machine Learning*, 8(3-4):231–357, 2015.
- [5] Elad Hazan et al. Introduction to online convex optimization. *Foundations and Trends® in Optimization*, 2(3-4):157–325, 2016.
- [6] Donald Goldfarb, Garud Iyengar, and Chaoxu Zhou. Linear convergence of stochastic frank wolfe variants. In *Artificial Intelligence and Statistics*, pages 1066–1074. PMLR, 2017.
- [7] Ali Dadras, Karthik Prakhya, and Alp Yurtsever. Federated frank-wolfe algorithm. In *Workshop on Federated Learning: Recent Advances and New Challenges (in Conjunction with NeurIPS 2022)*, 2022.
- [8] Robert M Freund, Paul Grigas, and Rahul Mazumder. An extended frank-wolfe method with “in-face” directions, and its application to low-rank matrix completion. *SIAM Journal on optimization*, 27(1):319–346, 2017.
- [9] Simon Lacoste-Julien, Martin Jaggi, Mark Schmidt, and Patrick Pletscher. Block-coordinate frank-wolfe optimization for structural svms. In *International Conference on Machine Learning*, pages 53–61. PMLR, 2013.
- [10] Yu-Xiang Wang, Veeranjaneyulu Sadhanala, Wei Dai, Willie Neiswanger, Suvrit Sra, and Eric Xing. Parallel and distributed block-coordinate frank-

- wolfe algorithms. In *International Conference on Machine Learning*, pages 1548–1557. PMLR, 2016.
- [11] Anton Osokin, Jean-Baptiste Alayrac, Isabella Lukasewitz, Puneet Dokania, and Simon Lacoste-Julien. Minding the gaps for block frank-wolfe optimization of structured svms. In *international conference on machine learning*, pages 593–602. PMLR, 2016.
 - [12] Sashank J Reddi, Suvrit Sra, Barnabás Póczos, and Alex Smola. Stochastic frank-wolfe methods for nonconvex optimization. In *2016 54th annual Allerton conference on communication, control, and computing (Allerton)*, pages 1244–1251. IEEE, 2016.
 - [13] Mingrui Zhang, Zebang Shen, Aryan Mokhtari, Hamed Hassani, and Amin Karbasi. One sample stochastic frank-wolfe. In *International Conference on Artificial Intelligence and Statistics*, pages 4012–4023. PMLR, 2020.
 - [14] Haihao Lu and Robert M Freund. Generalized stochastic frank–wolfe algorithm with stochastic “substitute” gradient for structured convex optimization. *Mathematical Programming*, 187(1):317–349, 2021.
 - [15] Ben Taskar, Vassil Chatalbashev, Daphne Koller, and Carlos Guestrin. Learning structured prediction models: A large margin approach. In *Proceedings of the 22nd international conference on Machine learning*, pages 896–903, 2005.
 - [16] Pin-Yu Chen, Huan Zhang, Yash Sharma, Jinfeng Yi, and Cho-Jui Hsieh. Zoo: Zeroth order optimization based black-box attacks to deep neural networks without training substitute models. In *Proceedings of the 10th ACM workshop on artificial intelligence and security*, pages 15–26, 2017.
 - [17] Yurii Nesterov and Vladimir Spokoiny. Random gradient-free minimization of convex functions. *Foundations of Computational Mathematics*, 17:527–566, 2017.

- [18] Krzysztof Choromanski, Mark Rowland, Vikas Sindhwani, Richard Turner, and Adrian Weller. Structured evolution with compact architectures for scalable policy optimization. In *International Conference on Machine Learning*, pages 970–978. PMLR, 2018.
- [19] Maryam Fazel, Rong Ge, Sham Kakade, and Mehran Mesbahi. Global convergence of policy gradient methods for the linear quadratic regulator. In *International conference on machine learning*, pages 1467–1476. PMLR, 2018.
- [20] Xiangru Lian, Yijun Huang, Yuncheng Li, and Ji Liu. Asynchronous parallel stochastic gradient for nonconvex optimization. *Advances in neural information processing systems*, 28, 2015.
- [21] Yu. Nesterov. Efficiency of coordinate descent methods on huge-scale optimization problems. *SIAM Journal on Optimization*, 22(2):341–362, 2012. doi:[10.1137/100802001](https://doi.org/10.1137/100802001). URL <https://doi.org/10.1137/100802001>.
- [22] John C Duchi, Peter L Bartlett, and Martin J Wainwright. Randomized smoothing for stochastic optimization. *SIAM Journal on Optimization*, 22(2): 674–701, 2012.
- [23] Peter Richtárik and Martin Takáč. Iteration complexity of randomized block-coordinate descent methods for minimizing a composite function. *Mathematical Programming*, 144(1):1–38, 2014.
- [24] Stephen J Wright. Coordinate descent algorithms. *Mathematical programming*, 151(1):3–34, 2015.
- [25] Yurii Nesterov and Sebastian U. Stich. Efficiency of the accelerated coordinate descent method on structured optimization problems. *SIAM Journal on Optimization*, 27(1):110–123, 2017. doi:[10.1137/16M1060182](https://doi.org/10.1137/16M1060182). URL <https://doi.org/10.1137/16M1060182>.
- [26] Alexander Gasnikov, Anton Novitskii, Vasilii Novitskii, Farshed Abdukhakimov, Dmitry Kamzolov, Aleksandr Beznosikov, Martin Takac,

- Pavel Dvurechensky, and Bin Gu. The power of first-order smooth optimization for black-box non-smooth problems. In *International Conference on Machine Learning*, pages 7241–7265. PMLR, 2022.
- [27] Alexander Gasnikov, Darina Dvinskikh, Pavel Dvurechensky, Eduard Gorbunov, Aleksander Beznosikov, and Alexander Lobanov. Randomized gradient-free methods in convex optimization. *arXiv preprint arXiv:2211.13566*, 2022.
- [28] Alexander Gasnikov, Anastasia Lagunovskaya, Ilnura Usmanova, and Fedor Fedorenko. Gradient-free proximal methods with inexact oracle for convex stochastic nonsmooth optimization problems on the simplex. *Automation and Remote Control*, 77:2018–2034, 2016.
- [29] Arya Akhavan, Evgenii Chzhen, Massimiliano Pontil, and Alexandre Tsybakov. A gradient estimator via l1-randomization for online zero-order optimization with two point feedback. *Advances in Neural Information Processing Systems*, 35:7685–7696, 2022.
- [30] Arkadij Semenovič Nemirovskij and David Borisovich Yudin. Problem complexity and method efficiency in optimization. 1983.
- [31] Ohad Shamir. An optimal algorithm for bandit and zero-order convex optimization with two-point feedback. *The Journal of Machine Learning Research*, 18(1):1703–1713, 2017.
- [32] Eduard Gorbunov, Pavel Dvurechensky, and Alexander Gasnikov. An accelerated method for derivative-free smooth stochastic convex optimization. *SIAM Journal on Optimization*, 32(2):1210–1238, 2022. doi:[10.1137/19M1259225](https://doi.org/10.1137/19M1259225). URL <https://doi.org/10.1137/19M1259225>.
- [33] Rie Johnson and Tong Zhang. Accelerating stochastic gradient descent using predictive variance reduction. *Advances in neural information processing systems*, 26, 2013.

- [34] Aaron Defazio, Francis Bach, and Simon Lacoste-Julien. Saga: A fast incremental gradient method with support for non-strongly convex composite objectives. *Advances in neural information processing systems*, 27, 2014.
- [35] Lam M Nguyen, Jie Liu, Katya Scheinberg, and Martin Takáč. Sarah: A novel method for machine learning problems using stochastic recursive gradient. In *International conference on machine learning*, pages 2613–2621. PMLR, 2017.
- [36] Filip Hanzely, Konstantin Mishchenko, and Peter Richtárik. Sega: Variance reduction via gradient sketching. *Advances in Neural Information Processing Systems*, 31, 2018.
- [37] Francis Bach and Vianney Perchet. Highly-smooth zero-th order online optimization. In *Conference on Learning Theory*, pages 257–283. PMLR, 2016.
- [38] Arya Akhavan, Massimiliano Pontil, and Alexandre Tsybakov. Exploiting higher order smoothness in derivative-free optimization and continuous bandits. *Advances in Neural Information Processing Systems*, 33:9017–9027, 2020.
- [39] Andrej Risteski and Yuanzhi Li. Algorithms and matching lower bounds for approximately-convex optimization. *Advances in Neural Information Processing Systems*, 29, 2016.
- [40] Lev Bogolubsky, Pavel Dvurechenskii, Alexander Gasnikov, Gleb Gusev, Yurii Nesterov, Andrei M Raigorodskii, Aleksey Tikhonov, and Maksim Zhukovskii. Learning supervised pagerank with gradient-based and gradient-free optimization methods. *Advances in neural information processing systems*, 29, 2016.
- [41] Anit Kumar Sahu, Dusan Jakovetic, Dragana Bajovic, and Soumya Kar. Distributed zeroth order optimization over random networks: A kiefer-wolfowitz stochastic approximation approach. In *2018 IEEE Conference on Decision and Control (CDC)*, pages 4951–4958. IEEE, 2018.

- [42] Anastasia Sergeevna Bayandina, Alexander V Gasnikov, and Anastasia A Lagunovskaya. Gradient-free two-point methods for solving stochastic nonsmooth convex optimization problems with small non-random noises. *Automation and Remote Control*, 79:1399–1408, 2018.
- [43] Darina Dvinskikh, Vladislav Tominin, Iaroslav Tominin, and Alexander Gasnikov. Noisy zeroth-order optimization for non-smooth saddle point problems. In *International Conference on Mathematical Optimization Theory and Operations Research*, pages 18–33. Springer, 2022.
- [44] Aleksandr Lobanov, Andrew Veprikov, Georgiy Konin, Aleksandr Beznosikov, Alexander Gasnikov, and Dmitry Kovalev. Non-smooth setting of stochastic decentralized convex optimization problem over time-varying graphs. *Computational Management Science*, 20(1):48, 2023.
- [45] Aleksandr Lobanov, Anton Anikin, Alexander Gasnikov, Alexander Gornov, and Sergey Chukanov. Zero-order stochastic conditional gradient sliding method for non-smooth convex optimization. *arXiv preprint arXiv:2303.02778*, 2023.
- [46] Anit Kumar Sahu, Manzil Zaheer, and Soumya Kar. Towards gradient free and projection free stochastic optimization. In *The 22nd International Conference on Artificial Intelligence and Statistics*, pages 3468–3477. PMLR, 2019.
- [47] Hongchang Gao and Heng Huang. Can stochastic zeroth-order frank-wolfe method converge faster for non-convex problems? In *International conference on machine learning*, pages 3377–3386. PMLR, 2020.
- [48] Zeeshan Akhtar and Ketan Rajawat. Zeroth and first order stochastic frank-wolfe algorithms for constrained optimization. *IEEE Transactions on Signal Processing*, 70:2119–2135, 2022.
- [49] Aleksandr Beznosikov, David Dobre, and Gauthier Gidel. Sarah frank-wolfe:

Methods for constrained optimization with best rates and practical features. *arXiv preprint arXiv:2304.11737*, 2023.

- [50] Kaiyi Ji, Zhe Wang, Yi Zhou, and Yingbin Liang. Improved zeroth-order variance reduced algorithms and analysis for nonconvex optimization. In *International conference on machine learning*, pages 3100–3109. PMLR, 2019.
- [51] John C Duchi, Michael I Jordan, Martin J Wainwright, and Andre Wibisono. Optimal rates for zero-order convex optimization: The power of two function evaluations. *IEEE Transactions on Information Theory*, 61(5):2788–2806, 2015.
- [52] Aleksandr Beznosikov, Abdurakhmon Sadiev, and Alexander Gasnikov. Gradient-free methods with inexact oracle for convex-concave stochastic saddle-point problem. In *International Conference on Mathematical Optimization Theory and Operations Research*, pages 105–119. Springer, 2020.
- [53] Abraham D Flaxman, Adam Tauman Kalai, and H Brendan McMahan. Online convex optimization in the bandit setting: gradient descent without a gradient. *arXiv preprint cs/0408007*, 2004.
- [54] Alexander V Gasnikov, Ekaterina A Krymova, Anastasia A Lagunovskaya, Il'nura N Usmanova, and Fedor A Fedorenko. Stochastic online optimization. single-point and multi-point non-linear multi-armed bandits. convex and strongly-convex case. *Automation and remote control*, 78:224–234, 2017.
- [55] Aleksandr Beznosikov, Vasilii Novitskii, and Alexander Gasnikov. One-point gradient-free methods for smooth and non-smooth saddle-point problems. In *Mathematical Optimization Theory and Operations Research: 20th International Conference, MOTOR 2021, Irkutsk, Russia, July 5–10, 2021, Proceedings 20*, pages 144–158. Springer, 2021.
- [56] Aryan Mokhtari, Hamed Hassani, and Amin Karbasi. Stochastic conditional gradient methods: From convex minimization to submodular maximization. *The Journal of Machine Learning Research*, 21(1):4232–4280, 2020.

- [57] Martin Jaggi. Revisiting frank-wolfe: Projection-free sparse convex optimization. In *International conference on machine learning*, pages 427–435. PMLR, 2013.
- [58] Sijia Liu, Bhavya Kailkhura, Pin-Yu Chen, Paishun Ting, Shiyu Chang, and Lisa Amini. Zeroth-order stochastic variance reduction for nonconvex optimization. *Advances in Neural Information Processing Systems*, 31, 2018.
- [59] Aleksandr Beznosikov, Eduard Gorbunov, and Alexander Gasnikov. Derivative-free method for composite optimization with applications to decentralized distributed optimization. *IFAC-PapersOnLine*, 53(2):4038–4043, 2020.
- [60] Li Deng. The mnist database of handwritten digit images for machine learning research. *IEEE Signal Processing Magazine*, 29(6):141–142, 2012.
- [61] Chih-Chung Chang and Chih-Jen Lin. Libsvm: a library for support vector machines. *ACM transactions on intelligent systems and technology (TIST)*, 2(3):1–27, 2011.

Приложение

А Вспомогательные леммы и факты

А.1 Квадрат нормы суммы

Для всех $x_1, \dots, x_n \in \mathbb{R}^n$, где $n \in \{2, 4\}$:

$$\|x_1 + x_2 + \dots + x_n\|^2 \leq n \|x_1\|^2 + \dots + n \|x_n\|^2.$$

А.2 Неравенство Коши-Шварца

Для всех $x, y \in \mathbb{R}^d$:

$$\langle x, y \rangle \leq \|x\| \|y\|.$$

А.3 Неравенства Юнга-Фенхеля

Для всех $x, y \in \mathbb{R}^d$ и $\beta > 0$:

$$2 \langle x, y \rangle \leq \beta^{-1} \|x\|^2 + \beta \|y\|^2.$$

А.4 Лемма о рекурсии

Лемма 5 (Вспомогательная лемма). *Для всех $x \in [0; 1)$ рассматривается функция*

$$\phi(x) := 1 - (1 - x)^\alpha - \max\{1, \alpha\}x.$$

Тогда $\phi(x) \leq 0$ для всех $0 \leq x < 1$ и $\alpha \in \mathbb{R}$.

Доказательство. Сначала рассмотрим случай, когда $\alpha \notin (0; 1)$. Тогда для всех $x < 1$ можно выписать неравенство Бернулли:

$$(1 - x)^\alpha \geq 1 - \alpha x.$$

Поэтому для $0 \leq x < 1$:

$$\phi(x) = 1 - (1 - x)^\alpha - \max\{1, \alpha\}x \leq 1 - (1 - x)^\alpha - \alpha x \leq 0.$$

Теперь рассмотрим случай $0 < \alpha < 1$, тогда $\phi(x)$ принимает вид:

$$\phi(x) = 1 - (1 - x)^\alpha - x.$$

Обратим внимание, что:

$$\phi''(x) = \alpha(1 - \alpha)(1 - x)^{\alpha-2} > 0.$$

Поэтому $\phi(x)$ выпукла на отрезке $[0; 1]$ и $\psi(0) = \psi(1) = 0$, что означает, что $\phi(x) \leq 0$ для всех $x \in [0; 1]$.

На этом доказательство закончено.

□

Лемма 6 (Лемма о рекурсии). *Предположим, что есть следующее рекуррентное соотношение для переменных $\{r_k\}_{k=0}^\infty \subset \mathbb{R}_+ \cup \{0\}$:*

$$r_{k+1} \leq \left(1 - \frac{\beta_0}{(k + k_0)^{\alpha_0}}\right) r_k + \sum_{i=1}^m \frac{\beta_i}{(k + k_0)^{\alpha_i}}, \quad (17)$$

где

- $\beta_i \in \mathbb{R}_+, \alpha_i \in \mathbb{R} \ \forall i \in \overline{1, m}$

- $0 \leq \alpha_0 \leq 1$, причем:

- Если $\alpha_0 = 0$, то:

$$0 < \beta_0 \leq 1 \text{ и } k_0 \geq \frac{2}{\beta_0} \max\{1, \max\{\alpha_i\}\};$$

- Если $0 < \alpha_0 < 1$, то:

$$\beta_0 > 0 \text{ и } k_0 \geq \max \left\{ \left(\frac{2}{\beta_0} \max\{1, \max\{\alpha_i\} - \alpha_0\} \right)^{\frac{1}{1-\alpha_0}}, \beta_0^{\frac{1}{\alpha_0}} \right\};$$

– Если $\alpha_0 = 1$, то:

$$k_0 \geq \beta_0 \geq 2 \max\{1, \max\{\alpha_i\} - 1\}.$$

Пусть $Q_{i^*} = \max\{\beta_{i^*}/\beta_0, r_0 k_0^{\alpha_{i^*}-\alpha_0}\}$ и $Q_{i \neq i^*} = \beta_i/\beta_0$, а i^* можно выбрать произвольно из множества $\overline{1, m}$. Тогда можно оценить сходимость последовательности $\{r_k\}_{k=0}^\infty$ к нулю:

$$r_k \leq 2 \cdot \sum_{i=1}^m \frac{Q_i}{(k + k_0)^{\alpha_i - \alpha_0}}, \quad (18)$$

Доказательство. Докажем утверждение (18) по индукции. Во-первых, заметим, что:

$$r_0 = r_0 \cdot \left(\frac{k_0}{0 + k_0} \right)^{\alpha_{i^*} - \alpha_0} \leq \frac{Q_{i^*}}{(0 + k_0)^{\alpha_{i^*} - \alpha_0}} \leq 2 \cdot \sum_{i=1}^m \frac{Q_i}{(0 + k_0)^{\alpha_i - \alpha_0}},$$

следовательно, нулевой шаг индукции верен.

Теперь предположим, что условие в (18) выполняется для какого-то k , покажем, что это условие будет выполняться для $k + 1$. Начнем с того, что впишем (18) в исходное рекуррентное соотношение (17) и воспользуемся тем, что $\beta_i \leq Q_i \beta_0$, а также будем предполагать, что $\beta_0 \leq k_0^{\alpha_0}$:

$$\begin{aligned} r_{k+1} &\leq \left(1 - \frac{\beta_0}{(k + k_0)^{\alpha_0}} \right) \cdot \left(2 \sum_{i=1}^m \frac{Q_i}{(k + k_0)^{\alpha_i - \alpha_0}} \right) + \sum_{i=1}^m \frac{\beta_i}{(k + k_0)^{\alpha_i}} \\ &\leq 2 \sum_{i=1}^m \frac{Q_i}{(k + k_0)^{\alpha_i - \alpha_0}} - \sum_{i=1}^m \frac{Q_i \beta_0}{(k + k_0)^{\alpha_i}} = \sum_{i=1}^m \left(\frac{2Q_i}{(k + k_0)^{\alpha_i - \alpha_0}} - \frac{Q_i \beta_0}{(k + k_0)^{\alpha_i}} \right). \end{aligned}$$

Необходимо показать, что для всех $i \in \overline{1, m}$ имеет место:

$$\frac{2Q_i}{(k + k_0)^{\alpha_i - \alpha_0}} - \frac{Q_i \beta_0}{(k + k_0)^{\alpha_i}} \leq \frac{2Q_i}{(k + k_0 + 1)^{\alpha_i - \alpha_0}}. \quad (19)$$

Перепишем это неравенство так, чтобы оно приняло более удобный вид:

$$\frac{2}{\beta_0} \underbrace{\left[1 - \left(1 - \frac{1}{k + k_0 + 1} \right)^{\alpha_i - \alpha_0} \right]}_{\textcircled{1}} \leq \left(\frac{1}{k + k_0} \right)^{\alpha_0}.$$

Используя лемму 5 с $x = (k + k_0 + 1)^{-1} \in [0; 1)$ и $\alpha = \alpha_i - \alpha_0$ можно получить:

$$\textcircled{1} \leq \max\{1, \alpha_i - \alpha_0\} \frac{1}{k + k_0 + 1} \leq \max\{1, \alpha_i - \alpha_0\} \frac{1}{k + k_0}.$$

Тогда неравенство (19) принимает вид:

$$\frac{2}{\beta_0} \max\{1, \alpha_i - \alpha_0\} \frac{1}{k + k_0} \leq \left(\frac{1}{k + k_0} \right)^{\alpha_0}.$$

Снова перепишем его в более удобной форме:

$$\frac{2}{\beta_0} \max\{1, \alpha_i - \alpha_0\} \leq (k + k_0)^{1-\alpha_0}. \quad (20)$$

Теперь рассмотрим два случая:

- Если $0 \leq \alpha_0 < 1$, то в этом случае $(k + k_0)^{1-\alpha_0} \geq k_0^{1-\alpha_0}$. Если взять:

$$k_0 \geq \left(\frac{2}{\beta_0} \max\{1, \max\{\alpha_i\} - \alpha_0\} \right)^{\frac{1}{1-\alpha_0}},$$

тогда согласно (20) желаемое неравенство (19) будет выполнено для всех $i \in \overline{1, m}$. Также надо учесть, что $\beta_0 \leq k_0^{\alpha_0}$, поэтому, если $\alpha_0 = 0$, получаем:

$$0 < \beta_0 \leq 1 \text{ и } k_0 \geq \frac{2}{\beta_0} \max\{1, \max\{\alpha_i\}\}$$

А если $0 < \alpha_0 < 1$, то получаем:

$$\beta_0 > 0 \text{ и } k_0 \geq \max \left\{ \left(\frac{2}{\beta_0} \max\{1, \max\{\alpha_i\} - \alpha_0\} \right)^{\frac{1}{1-\alpha_0}}, \beta_0^{\frac{1}{\alpha_0}} \right\};$$

- Если $\alpha_0 = 1$, то тогда неравенство (20) примет форму:

$$\frac{2}{\beta_0} \max\{1, \alpha_i - 1\} \leq 1.$$

Поэтому если взять

$$\beta_0 \geq 2 \max\{1, \max\{\alpha_i\} - 1\},$$

тогда снова согласно (20) желаемое неравенство (19) будет выполнено для всех $i \in \overline{1, m}$. Также надо учесть, что $\beta_0 \leq k_0^{\alpha_0}$:

$$k_0 \geq \beta_0 \geq 2 \max\{1, \max\{\alpha_i\} - 1\}.$$

На этом доказательство закончено. □

В Доказательство сходимости JAGUAR

В.1 Доказательство Леммы 1

Доказательство. Начнем расписывать $\tilde{\nabla} f_\delta(x, \xi_{1,d}^\pm)$:

$$\begin{aligned} & \mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x, \xi_{1,d}^\pm) - \nabla f(x) \right\|^2 \right] \\ &= \mathbb{E} \left[\left\| \sum_{i=1}^d \frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} e_i - \nabla f(x) \right\|^2 \right] \\ &= \mathbb{E} \left[\left\| \sum_{i=1}^d \left(\frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} - \langle \nabla f(x), e_i \rangle \right) e_i \right\|^2 \right] \\ &\stackrel{(\star)}{=} \sum_{i=1}^d \mathbb{E} \left[\left\| \left(\frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} - \langle \nabla f(x), e_i \rangle \right) e_i \right\|^2 \right] \\ &= \sum_{i=1}^d \mathbb{E} \left[\left| \frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} - \langle \nabla f(x), e_i \rangle \right|^2 \right]. \end{aligned}$$

Равенство (\star) выполняется, так как $\langle e_i, e_j \rangle = 0$, если $i \neq j$. Теперь оценим

значение члена суммы:

$$\begin{aligned}
& \mathbb{E} \left[\left| \frac{f_\delta(x + \tau e_i, \xi_i^+) - f_\delta(x - \tau e_i, \xi_i^-)}{2\tau} - \langle \nabla f(x), e_i \rangle \right|^2 \right] \\
&= \mathbb{E} \left[\left| \frac{f(x + \tau e_i, \xi_i^+) - f(x - \tau e_i, \xi_i^-)}{2\tau} - \langle \nabla f(x), e_i \rangle \right. \right. \\
&\quad \left. \left. + \frac{\delta(x + \tau e_i, \xi_i^+) - \delta(x - \tau e_i, \xi_i^-)}{2\tau} \right|^2 \right] \\
&\stackrel{A.1}{\leq} \frac{1}{2\tau^2} \underbrace{\mathbb{E} \left[\left| f(x + \tau e_i, \xi_i^+) - f(x - \tau e_i, \xi_i^-) - 2 \langle \nabla f(x), \tau e_i \rangle \right|^2 \right]}_{\textcircled{1}} + \frac{2\Delta^2}{\tau^2}.
\end{aligned}$$

Последнее неравенство выполняется, так как шум ограничен (8). Рассмотрим $\textcircled{1}$. Используя A.1 с $n = 4$, получим:

$$\begin{aligned}
& \mathbb{E} \left[\left| f(x + \tau e_i, \xi_i^+) - f(x - \tau e_i, \xi_i^-) - \langle \nabla f(x), 2\tau e_i \rangle \right|^2 \right] \\
&\leq 4\mathbb{E} \left[\left| f(x + \tau e_i, \xi_i^+) - f(x, \xi_i^+) - \langle \nabla f(x, \xi_i^+), \tau e_i \rangle \right|^2 \right] \\
&\quad + 4\mathbb{E} \left[\left| -f(x - \tau e_i, \xi_i^-) + f(x, \xi_i^-) + \langle \nabla f(x, \xi_i^-), -\tau e_i \rangle \right|^2 \right] \quad (21) \\
&\quad + 4\mathbb{E} \left[\left| f(x, \xi_i^+) - f(x, \xi_i^-) \right|^2 \right] \\
&\quad + 4\mathbb{E} \left[\left| \langle \nabla f(x, \xi_i^+) + \nabla f(x, \xi_i^-) - 2\nabla f(x), \tau e_i \rangle \right|^2 \right].
\end{aligned}$$

Оценим все эти четыре компоненты по отдельности. Поскольку функции $f(x, \xi_i^+)$ и $f(x, \xi_i^-)$ являются $L(\xi_i^\pm)$ -гладкими (7), то уже есть оценки для первой и второй:

$$\begin{aligned}
& \mathbb{E} \left[\left| f(x + \tau e_i, \xi_i^+) - f(x, \xi_i^+) - \langle \nabla f(x, \xi_i^+), \tau e_i \rangle \right|^2 \right] \leq \frac{L^2 \tau^2}{4}, \\
& \mathbb{E} \left[\left| -f(x - \tau e_i, \xi_i^-) + f(x, \xi_i^-) + \langle \nabla f(x, \xi_i^-), -\tau e_i \rangle \right|^2 \right] \leq \frac{L^2 \tau^2}{4}. \quad (22)
\end{aligned}$$

Если рассматривать приближение ДОС (12), то третий член в (21) равен нулю, так как $\xi_i^+ = \xi_i^-$, если рассматривать случай ООС (13), то можно

воспользоваться A.1 с $n = 2$ и (10):

$$\begin{aligned} \mathbb{E} \left[|f(x, \xi_i^+) - f(x, \xi_i^-)|^2 \right] &\leq 2\mathbb{E} \left[|f(x, \xi_i^+) - f(x)|^2 \right] \\ &\quad + 2\mathbb{E} \left[|f(x, \xi_i^-) - f(x)|^2 \right] \leq 4\sigma_f^2. \end{aligned} \quad (23)$$

Рассмотрим последнюю компоненту в (21) и, используя неравенство Коши-Шварца A.2 и (9), получим:

$$\mathbb{E} \left[|\langle \nabla f(x, \xi_i^+) - \nabla f(x), \tau e_i \rangle|^2 \right] \leq \mathbb{E} \left[\|\nabla f(x, \xi_i^+) - \nabla f(x)\|^2 \right] \tau^2 \leq \sigma_{\nabla}^2 \tau^2. \quad (24)$$

Используя (22), (23) и (24), получаем:

$$\mathbb{E} \left[\left\| \tilde{\nabla} f_{\delta} \left(x, \xi_{1,d}^{\pm} \right) - \nabla f(x) \right\|^2 \right] \leq d \left(L^2 \tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_{\nabla}^2 + \frac{2\Delta^2}{\tau^2} \right).$$

В случае двухточечной обратной связи $\sigma_f = 0$, а в детерминированном случае $\sigma_{\nabla} = \sigma_f = 0$.

На этом доказательство закончено. □

B.2 Доказательство Леммы 2

Доказательство. Начнем расписывать h^{k+1} :

$$\begin{aligned} \mathbb{E} \left[\|h^{k+1} - \nabla f(x^{k+1})\|^2 \right] &= \mathbb{E} \left[\left\| h^k + \tilde{\nabla}_i f_{\delta}(x^{k+1}, \xi^{\pm}) - \langle h^k, e_i \rangle e_i - \nabla f(x^{k+1}) \right\|^2 \right] \\ &= \mathbb{E} \left[\left\| (I - e_i e_i^T) (h^k - \nabla f(x^k)) + e_i e_i^T \left(\tilde{\nabla} f_{\delta}(x^{k+1}, \xi^{\pm}) - \nabla f(x^{k+1}) \right) \right. \right. \\ &\quad \left. \left. + (I - e_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right] \\ &= \underbrace{\mathbb{E} \left[\left\| (I - e_i e_i^T) (h^k - \nabla f(x^k)) \right\|^2 \right]}_{\textcircled{1}} + \underbrace{\mathbb{E} \left[\left\| e_i e_i^T \left(\tilde{\nabla} f_{\delta}(x^{k+1}, \xi^{\pm}) - \nabla f(x^{k+1}) \right) \right\|^2 \right]}_{\textcircled{2}} \\ &\quad + \underbrace{\mathbb{E} \left[\left\| (I - e_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right]}_{\textcircled{3}} \\ &\quad + \underbrace{\mathbb{E} \left[2 \langle (I - e_i e_i^T) (h^k - \nabla f(x^k)), (I - e_i e_i^T) (\nabla f(x^{k+1}) - \nabla f(x^k)) \rangle \right]}_{\textcircled{4}}. \end{aligned}$$

В последнем равенстве два оставшихся скалярных произведения равны нулю, так как $e_i e_i^T (I - e_i e_i^T) = e_i e_i^T - e_i e_i^T = 0$. Рассмотрим ①. Используя обозначение $v := h^k - \nabla f(x^k)$, получим:

$$\begin{aligned} \mathbb{E} \left[\left\| (I - e_i e_i^T) (h^k - \nabla f(x^k)) \right\|^2 \right] &= \mathbb{E} \left[v^T (I - e_i e_i^T)^T (I - e_i e_i^T) v \right] \\ &= \mathbb{E} \left[v^T (I - e_i e_i^T) v \right] \\ &= \mathbb{E} \left[\mathbb{E}_k \left[v^T (I - e_i e_i^T) v \right] \right], \end{aligned}$$

где $\mathbb{E}_k[\cdot]$ – условное математическое ожидание с фиксированной случайностью всех шагов до k . Поскольку на шаге k векторы e_i генерируются независимо, получаем:

$$\begin{aligned} \mathbb{E} \left[\mathbb{E}_k \left[v^T (I - e_i e_i^T) v \right] \right] &= \mathbb{E} \left[v^T \mathbb{E}_k \left[(I - e_i e_i^T) \right] v \right] \\ &= \left(1 - \frac{1}{d} \right) \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right]. \end{aligned}$$

Рассмотрим ②. Поскольку i генерируются независимо, x^k не зависит от e_i , сгенерированных на шаге k , то можно применить ту же технику, что и в оценке ①:

$$\mathbb{E} \left[\left\| e_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \right\|^2 \right] = \frac{1}{d} \mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right\|^2 \right].$$

Рассмотрим ③. Используем ту же технику, что и при оценке ①, а также (7):

$$\mathbb{E} \left[\left\| (I - e_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right] \leq \left(1 - \frac{1}{d} \right) L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right].$$

Рассмотрим ④. Используя неравенство Юнга-Фенхеля А.3 с $\beta = 2d$ и (7), получаем:

$$\textcircled{4} \leq \left(1 - \frac{1}{d} \right) \left(\frac{1}{2d} \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] + 2dL^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \right).$$

Используя лемму 1 и оценки на слагаемые получаем:

$$\begin{aligned} \mathbb{E} \left[\|h^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq \left(1 - \frac{1}{2d} \right) \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \\ &\quad + 2dL^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \\ &\quad + L^2 \tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_\nabla^2 + \frac{2\Delta^2}{\tau^2}. \end{aligned}$$

На этом доказательство закончено. □

В.3 Доказательство Леммы 3

Доказательство. Начнем расписывать ρ^{k+1} :

$$\begin{aligned}
\mathbb{E} \left[\left\| \rho^{k+1} - \nabla f(x^{k+1}) \right\|^2 \right] &= \mathbb{E} \left[\left\| h^k + d \tilde{\nabla}_i f_\delta(x^{k+1}, \xi^\pm) - d \langle h^k, e_i \rangle e_i - \nabla f(x^{k+1}) \right\|^2 \right] \\
&= \mathbb{E} \left[\left\| (I - de_i e_i^T) (h^k - \nabla f(x^k)) + de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \right. \right. \\
&\quad \left. \left. + (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right] \\
&= \underbrace{\mathbb{E} \left[\left\| (I - de_i e_i^T) (h^k - \nabla f(x^k)) \right\|^2 \right]}_{\textcircled{1}} + \underbrace{\mathbb{E} \left[\left\| de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \right\|^2 \right]}_{\textcircled{2}} \\
&\quad + \underbrace{\mathbb{E} \left[\left\| (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right]}_{\textcircled{3}} \\
&\quad + \underbrace{\mathbb{E} \left[2 \langle (I - de_i e_i^T) (h^k - \nabla f(x^k)), (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \rangle \right]}_{\textcircled{4}} \\
&\quad + \underbrace{\mathbb{E} \left[2 \langle de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right), (I - de_i e_i^T) (h^k - \nabla f(x^k)) \rangle \right]}_{\textcircled{5}} \\
&\quad + \underbrace{\mathbb{E} \left[2 \langle (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})), de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \rangle \right]}_{\textcircled{6}}.
\end{aligned}$$

Рассмотрим $\textcircled{1}$. Используя обозначение $v := h^k - \nabla f(x^k)$, получим:

$$\begin{aligned}
\mathbb{E} \left[\left\| (I - de_i e_i^T) (h^k - \nabla f(x^k)) \right\|^2 \right] &= \mathbb{E} \left[v^T (I - de_i e_i^T)^T (I - de_i e_i^T) v \right] \\
&= \mathbb{E} \left[v^T (I - (2d - d^2) e_i e_i^T) v \right] \\
&= \mathbb{E} \left[\mathbb{E}_k \left[v^T (I - (2d - d^2) e_i e_i^T) v \right] \right],
\end{aligned}$$

где $\mathbb{E}_k[\cdot]$ – условное математическое ожидание с фиксированной случайностью всех шагов до k . Поскольку на шаге k векторы e_i генерируются независимо,

получаем:

$$\begin{aligned}\mathbb{E} \left[\mathbb{E}_k \left[v^T (I - (2d - d^2)e_i e_i^T) v \right] \right] &= \mathbb{E} \left[v^T \mathbb{E}_k \left[I - (2d - d^2)e_i e_i^T \right] v \right] \\ &= (d - 1) \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right].\end{aligned}$$

Рассмотрим ②. Поскольку i генерируются независимо, x^k не зависит от e_i , сгенерированных на шаге k , то можно применить ту же технику, что и в оценке ①:

$$\mathbb{E} \left[\left\| de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \right\|^2 \right] = d \mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right\|^2 \right].$$

Рассмотрим ③. Используем ту же технику, что и при оценке ①, а также (7):

$$\mathbb{E} \left[\left\| (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right\|^2 \right] \leq (d - 1) L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right].$$

Рассмотрим ④, ⑤, ⑥. Используя неравенство Юнга-Фенхеля А.3 с $\beta = 2$, $\beta = 1$, $\beta = \frac{1}{2}$ и (7), получаем:

$$\begin{aligned}\textcircled{4} &\leq (d - 1) \left(2\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] + \frac{1}{2} L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \right); \\ \textcircled{5} &\leq (d - 1) \left(\mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right\|^2 \right] + \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \right); \\ \textcircled{6} &\leq (d - 1) \left(\frac{1}{2} L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] + 2\mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right\|^2 \right] \right).\end{aligned}$$

Используя лемму 1 и оценки на слагаемые получаем:

$$\begin{aligned}\mathbb{E} \left[\|\rho^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq 4d \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \\ &\quad + 2dL^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right] \\ &\quad + 4d^2 \left(L^2 \tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_\nabla^2 + \frac{2\Delta^2}{\tau^2} \right).\end{aligned}$$

На этом доказательство закончено. □

В.4 Доказательство Леммы 4

Доказательство. Начнем расписывать g^{k+1} :

$$\begin{aligned}
& \mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|^2 \right] \\
&= \mathbb{E} \left[\|g^k - \nabla f(x^k) + \nabla f(x^k) - \nabla f(x^{k+1}) + (g^{k+1} - g^k)\|^2 \right] \\
&= \mathbb{E} \left[\|g^k - \nabla f(x^k) + \nabla f(x^k) - \nabla f(x^{k+1}) + \eta_k(\rho^{k+1} - g^k)\|^2 \right] \\
&= \mathbb{E} \left[\left\| (1 - \eta_k)(g^k - \nabla f(x^k)) + (1 - \eta_k)(\nabla f(x^k) - \nabla f(x^{k+1})) \right. \right. \\
&\quad \left. \left. + \eta_k(\rho^{k+1} - \nabla f(x^{k+1})) \right\|^2 \right] \\
&= (1 - \eta_k)^2 \mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] + \eta_k^2 \mathbb{E} \left[\|\rho^{k+1} - \nabla f(x^{k+1})\|^2 \right] \\
&\quad + \underbrace{(1 - \eta_k)^2 \mathbb{E} \left[\|\nabla f(x^k) - \nabla f(x^{k+1})\|^2 \right]}_{\textcircled{1}} \\
&\quad + \underbrace{(1 - \eta_k)^2 \mathbb{E} \left[2 \langle g^k - \nabla f(x^k), \nabla f(x^k) - \nabla f(x^{k+1}) \rangle \right]}_{\textcircled{2}} \\
&\quad + \underbrace{\eta_k(1 - \eta_k) \mathbb{E} \left[2 \langle \rho^{k+1} - \nabla f(x^{k+1}), g^k - \nabla f(x^k) \rangle \right]}_{\textcircled{3}} \\
&\quad + \underbrace{\eta_k(1 - \eta_k) \mathbb{E} \left[2 \langle \nabla f(x^k) - \nabla f(x^{k+1}), \rho^{k+1} - \nabla f(x^{k+1}) \rangle \right]}_{\textcircled{4}}.
\end{aligned}$$

Рассмотрим $\textcircled{1}$. Используя (7), получаем:

$$\textcircled{1} \leq L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right].$$

Рассмотрим $\textcircled{2}$. Используя неравенство Юнга-Фенхеля А.3 с $\beta = \frac{2}{\eta_k}$ и (7), получается:

$$\textcircled{2} \leq \frac{\eta_k}{2} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] + \frac{2}{\eta_k} L^2 \mathbb{E} \left[\|x^{k+1} - x^k\|^2 \right].$$

Рассмотрим $\textcircled{3}$. Так как ξ^+ и ξ^- генерируются независимо, то получается:

$$\textcircled{3} = \mathbb{E} \left[\langle \mathbb{E}_k [\rho^{k+1} - \nabla f(x^{k+1})], \nabla g^k - f(x^k) \rangle \right],$$

где $\mathbb{E}_k[\cdot]$ – условное ожидание с фиксированной случайностью всех шагов до k . Упростим ③:

$$\begin{aligned}\mathbb{E}_k [\rho^{k+1} - \nabla f(x^{k+1})] &= \mathbb{E}_k \left[(I - de_i e_i^T) (h^k - \nabla f(x^k)) \right. \\ &\quad \left. + de_i e_i^T \left(\tilde{\nabla} f_\delta(x^{k+1}, \xi^\pm) - \nabla f(x^{k+1}) \right) \right. \\ &\quad \left. + (I - de_i e_i^T) (\nabla f(x^k) - \nabla f(x^{k+1})) \right] \\ &= \tilde{\nabla} f_\delta(x^{k+1}) - \nabla f(x^{k+1}).\end{aligned}$$

Используя неравенство Юнга-Фенхеля А.3 с $\beta = \frac{1}{2}$, получается:

$$\begin{aligned}\textcircled{3} &\leq 2\mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}) - \nabla f(x^{k+1}) \right\|^2 \right] \\ &\quad + \frac{1}{2}\mathbb{E} \left[\left\| g^k - \nabla f(x^k) \right\|^2 \right].\end{aligned}$$

Рассмотрим ④. Используя неравенство Юнга-Фенхеля А.3 с $\beta = \eta_k^2$ и (7), получается:

$$\begin{aligned}\textcircled{4} &\leq \frac{1}{\eta_k^2} L^2 \mathbb{E} \left[\left\| x^{k+1} - x^k \right\|^2 \right] \\ &\quad + \eta_k^2 \mathbb{E} \left[\left\| \tilde{\nabla} f_\delta(x^{k+1}) - \nabla f(x^{k+1}) \right\|^2 \right].\end{aligned}$$

Используя лемму 1 и оценки на слагаемые получаем:

$$\begin{aligned}\mathbb{E} \left[\left\| g^{k+1} - \nabla f(x^{k+1}) \right\|^2 \right] &\leq (1 - \eta_k) \mathbb{E} \left[\left\| g^k - \nabla f(x^k) \right\|^2 \right] \\ &\quad + \eta_k^2 \mathbb{E} \left[\left\| \rho^{k+1} - \nabla f(x^{k+1}) \right\|^2 \right] \\ &\quad + \frac{4L^2}{\eta_k} \mathbb{E} \left[\left\| x^{k+1} - x^k \right\|^2 \right] \\ &\quad + 3\eta_k d \left(L^2 \tau^2 + \frac{2\Delta^2}{\tau^2} \right).\end{aligned}$$

На этом доказательство закончено. □

С Доказательство сходимости алгоритма Франка-Вульфа с JAGUAR

С.1 Доказательство Теоремы 1

Доказательство. Начнем с того, что выпишем результат из Леммы 2 с $\sigma_f = \sigma_{\nabla} = 0$ и подставим $\gamma_k = \frac{4}{k+8d}$:

$$\begin{aligned} \mathbb{E} \left[\|h^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq \left(1 - \frac{1}{2d} \right) \mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] \\ &\quad + \frac{32dL^2D^2}{(k+8d)^2} + L^2\tau^2 + \frac{2\Delta^2}{\tau^2}. \end{aligned}$$

Теперь используем Лемму 6 с $\alpha_0 = 0, \beta_0 = 1/2d, k_0 = 8d; \alpha_1 = 2, \beta_1 = 32dL^2D^2; \alpha_2 = 0, \beta_2 = L^2\tau^2 + \frac{2\Delta^2}{\tau^2}$ и $i^* = 1$:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2 \max \left\{ L^2D^2, \|h^0 - \nabla f(x^0)\|^2 \right\}}{(k+8d)^2} + dL^2\tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Если $h^0 = \tilde{\nabla} f_{\delta}(x^0)$, то получим:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2L^2D^2}{(k+8d)^2} + dL^2\tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

На этом доказательство закончено. □

С.2 Доказательство Теоремы 2

Доказательство. Начнем с того, что запишем результат Леммы 2 из [56]. При предположениях 4, 14, 15 и 16 выполняется следующее неравенство:

$$\begin{aligned} \mathbb{E} \left[f(x^{k+1}) - f(x^*) \right] &\leq (1 - \gamma_k) \mathbb{E} \left[f(x^k) - f(x^*) \right] + \gamma_k D \mathbb{E} \left[\|h^k - \nabla f(x^k)\| \right] \\ &\quad + \frac{LD^2\gamma_k^2}{2}. \end{aligned}$$

Для оценки $\mathbb{E} [\|h^k - \nabla f(x^k)\|]$, используется неравенство Йенсена:

$$\mathbb{E} [\|h^k - \nabla f(x^k)\|] \leq \sqrt{\mathbb{E} [\|h^k - \nabla f(x^k)\|^2]}.$$

Тогда получается:

$$\mathbb{E} [\|h^k - \nabla f(x^k)\|] = \mathcal{O} \left(\frac{dLD}{k + 8d} + \sqrt{d}L\tau + \frac{\sqrt{d}\Delta}{\tau} \right).$$

Подставим $\gamma_k = \frac{4}{k+8d}$, тогда рекуррентное соотношение будет выглядеть:

$$\begin{aligned} \mathbb{E} [f(x^{k+1}) - f(x^*)] &\leq \left(1 - \frac{4}{k + 8d}\right) \mathbb{E} [f(x^k) - f(x^*)] \\ &\quad + \frac{1}{(k + 8d)^2} \mathcal{O}(dLD^2) \\ &\quad + \frac{1}{k + 8d} \mathcal{O} \left(\sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau} \right). \end{aligned}$$

Теперь используем Лемму 6 с $\alpha_0 = 1, \beta_0 = 4, k_0 = 8d; \alpha_1 = 2, \beta_1 = dLD^2; \alpha_2 = 1, \beta_2 = \sqrt{d}L\tau D + \frac{\sqrt{d}\Delta D}{\tau}$ и $i^* = 1$, получаем:

$$\mathbb{E} [f(x^k) - f(x^*)] = \mathcal{O} \left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{k + 8d} + \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau} \right).$$

На этом доказательство закончено. □

С.3 Доказательство Теоремы 3

Доказательство. Начнем с того, что выпишем результат из Леммы 2 и подставим $\gamma_k = \frac{4}{k+8d^{3/2}}$:

$$\begin{aligned} \mathbb{E} [\|h^{k+1} - \nabla f(x^{k+1})\|^2] &\leq \left(1 - \frac{1}{2d}\right) \mathbb{E} [\|h^k - \nabla f(x^k)\|^2] \\ &\quad + \frac{32dL^2D^2}{(k + 8d^{3/2})^2} + L^2\tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_{\nabla}^2 + \frac{2\Delta^2}{\tau^2}. \end{aligned}$$

Теперь используем лемму 6 с $\alpha_0 = 0, \beta_0 = 1/2d, k_0 = 8d^{3/2}; \alpha_1 = 2, \beta_1 = 32dL^2D^2; \alpha_2 = 0, \beta_2 = L^2\tau^2 + \frac{8\sigma_f^2}{\tau^2} + 2\sigma_{\nabla}^2 + \frac{2\Delta^2}{\tau^2}$ и $i^* = 1$:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2 \max \left\{ L^2 D^2, d\mathbb{E} \left[\|h^0 - \nabla f(x^0)\|^2 \right] \right\}}{(k + 8d^{3/2})^2} + dL^2\tau^2 + \frac{d\sigma_f^2}{\tau^2} + d\sigma_{\nabla}^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Если $h^0 = \tilde{\nabla} f_{\delta} \left(x^0, \xi_{1,d}^{\pm} \right)$, то получим:

$$\mathbb{E} \left[\|h^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^2 L^2 D^2}{(k + 8d^{3/2})^2} + dL^2\tau^2 + \frac{d\sigma_f^2}{\tau^2} + d\sigma_{\nabla}^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Выпишем результат из Леммы 3 и подставим $\gamma_k = \frac{4}{k+8d^{3/2}}$:

$$\mathbb{E} \left[\|\rho^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{d^3 \max \left\{ L^2 D^2, d\mathbb{E} \left[\|h^0 - \nabla f(x^0)\|^2 \right] \right\}}{(k + 8d^{3/2})^2} + d^2 L^2 \tau^2 + \frac{d^2 \sigma_f^2}{\tau^2} + d^2 \sigma_{\nabla}^2 + \frac{d^2 \Delta^2}{\tau^2} \right).$$

Выпишем результат из Леммы 4 и подставим $\gamma_k = \frac{4}{k+8d^{3/2}}$ и $\eta_k = \frac{4}{(k+8d^{3/2})^{2/3}}$:

$$\begin{aligned} \mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|^2 \right] &\leq \left(1 - \frac{4}{(k + 8d^{3/2})^{2/3}} \right) \mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] \\ &+ \frac{1}{(k + 8d^{3/2})^{10/3}} \mathcal{O} \left(d^3 \max \left\{ L^2 D^2, d\mathbb{E} \left[\|h^0 - \nabla f(x^0)\|^2 \right] \right\} \right) \\ &+ \frac{1}{(k + 8d^{3/2})^{4/3}} \mathcal{O} \left(L^2 D^2 + d^2 L^2 \tau^2 + \frac{d^2 \sigma_f^2}{\tau^2} + d^2 \sigma_{\nabla}^2 + \frac{d^2 \Delta^2}{\tau^2} \right) \\ &+ \frac{1}{(k + 8d^{3/2})^{2/3}} \left(dL^2\tau^2 + \frac{2d\Delta^2}{\tau^2} \right). \end{aligned}$$

Используя Лемму 6 с $\alpha_0 = 2/3, \beta_0 = 4, k_0 = 8d^{3/2}; \alpha_1 = 10/3, \beta_1 = d^3 \max \left\{ L^2 D^2, d\mathbb{E} \left[\|h^0 - \nabla f(x^0)\|^2 \right] \right\}; \alpha_2 = 4/3, \beta_2 = L^2 D^2 + d^2 L^2 \tau^2 + \frac{d^2 \sigma_f^2}{\tau^2} + d^2 \sigma_{\nabla}^2 + \frac{d^2 \Delta^2}{\tau^2}$;

$\alpha_3 = 2/3$, $\beta_3 = dL^2\tau^2 + \frac{d\Delta^2}{\tau^2}$ и $i^* = 2$ получаем:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{\max \left\{ L^2 D^2 + d^2 \sigma_f^2 / \tau^2 + d^2 \sigma_{\nabla}^2, d \mathbb{E} \left[\|g^0 - \nabla f(x^0)\|^2 \right] \right\}}{(k + 8d^{3/2})^{2/3}} + \frac{d^4 \mathbb{E} \left[\|h^0 - \nabla f(x^0)\|^2 \right]}{(k + 8d^{3/2})^{8/3}} + dL^2\tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

Если $h^0 = g^0 = \tilde{\nabla} f_{\delta} \left(x^0, \xi_{1,d}^{\pm} \right)$, то получим:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{L^2 D^2 + d^2 \sigma_f^2 / \tau^2 + d^2 \sigma_{\nabla}^2}{(k + 8d^{3/2})^{2/3}} + dL^2\tau^2 + \frac{d\Delta^2}{\tau^2} \right).$$

На этом доказательство закончено. □

С.4 Доказательство Теоремы 4

Доказательство. Начнем с того, что запишем результат Леммы 2 из [56]. При предположениях 7, 14, 15, 16 выполняется следующее неравенство:

$$\mathbb{E} \left[f(x^{k+1}) - f(x^*) \right] \leq (1 - \gamma_k) \mathbb{E} \left[f(x^k) - f(x^*) \right] + \gamma_k D \mathbb{E} \left[\|h^k - \nabla f(x^k)\| \right] + \frac{LD^2\gamma_k^2}{2}.$$

Для оценки $\mathbb{E} \left[\|g^k - \nabla f(x^k)\| \right]$, используется неравенство Йенсена:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\| \right] \leq \sqrt{\mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right]}.$$

Тогда получается:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|^2 \right] = \mathcal{O} \left(\frac{LD + d\sigma_f/\tau + d\sigma_{\nabla}}{(k + 8d^{3/2})^{1/3}} + \sqrt{d}L\tau + \frac{\sqrt{d}\Delta}{\tau} \right).$$

Подставим $\gamma_k = \frac{4}{k+8d^{3/2}}$, тогда рекуррентное соотношение будет выглядеть:

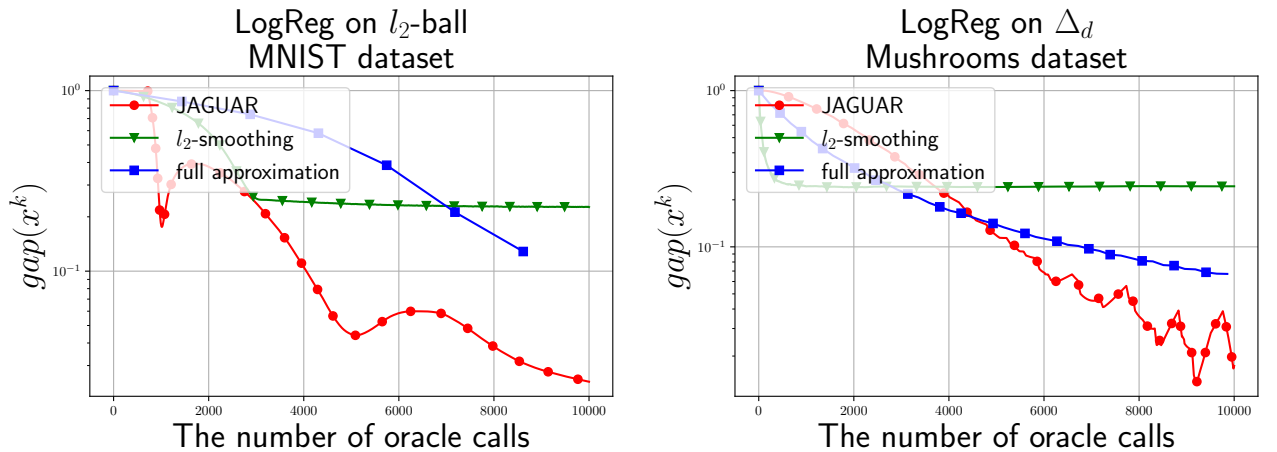
$$\begin{aligned}\mathbb{E} [f(x^{k+1}) - f(x^*)] &\leq \left(1 - \frac{4}{k+8d^{3/2}}\right) \mathbb{E} [f(x^k) - f(x^*)] \\ &\quad + \frac{8LD^2}{(k+8d^{3/2})^2} \\ &\quad + \frac{1}{(k+8d^{3/2})^{4/3}} \mathcal{O}(LD^2 + d\sigma_f D/\tau + d\sigma_{\nabla} D) \\ &\quad + \frac{1}{k+8d^{3/2}} \mathcal{O}\left(\sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau}\right).\end{aligned}$$

Используя Лемму 6 с $\alpha_0 = 1, \beta_0 = 4, k_0 = 8d^{3/2}; \alpha_1 = 2, \beta_1 = 8LD^2; \alpha_2 = 4/3; \beta_2 = LD^2 + d\sigma_f D/\tau + d\sigma_{\nabla} D; \alpha_3 = 1, \beta_3 = \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau}$ и $i^* = 2$, получаем:

$$\begin{aligned}\mathbb{E} [f(x^k) - f(x^*)] &= \mathcal{O}\left(\frac{\max\{LD^2 + d\sigma_f D/\tau + d\sigma_{\nabla} D, \sqrt{d}(f(x^0) - f(x^*))\}}{(k+8d^{3/2})^{1/3}}\right. \\ &\quad \left.+ \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau}\right).\end{aligned}$$

На этом доказательство закончено. □

С.5 Дополнительные эксперименты









Рис. 4: Детерминированный алгоритм Франка-Вульфа.


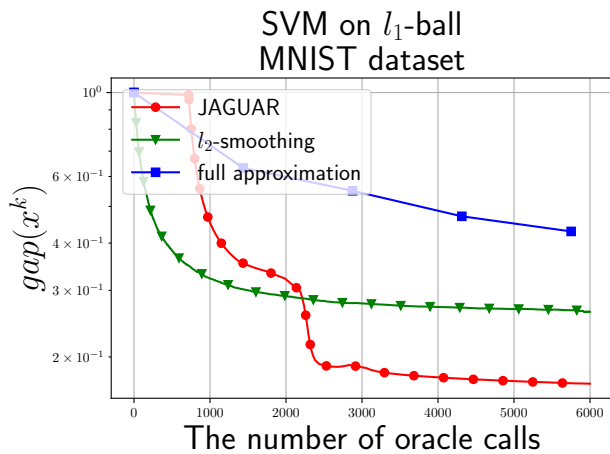


Рис. 5: Стохастический алгоритм (ООС) Франка-Вульфа.









Рис. 6: Стохастический алгоритм (ДОС) Франка-Вульфа.