

Аппроксимации градиента с помощью оракула нулевого порядка и техники запоминания

Александр Иванович Богданов

Научный руководитель: к.ф.-м.н. А. Н. Безносиков

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 03.03.01 Прикладные математика и физика

2024

Аппроксимация градента

Проблема: Ставится задача оптимизации с доступом только к зашумленному нулевому оракулу.

Цель: Предложить робастый алгоритм аппроксимации градиента, использующий $\mathcal{O}(1)$ вызовов оракула на каждой итерации.

Решение: Предлагается аппроксимация градиента JAGUAR, которая использует технику запоминания.

Постановка задачи

Рассматриваются две оптимизационные задачи на произвольном множестве $Q \subseteq \mathbb{R}^d$:

1. Детерминированная

$$\min_{x \in Q} f(x).$$

Доступ к $f_\delta(x) := f(x) + \delta(x)$, где $\delta(x)$ – шум.

2. Стохастическая

$$\min_{x \in Q} f(x) := \mathbb{E}_{\xi \sim \pi} [f(x, \xi)].$$

Доступ к $f_\delta(x, \xi) := f(x, \xi) + \delta(x, \xi)$, где $\delta(x, \xi)$ – шум.

Алгоритм 1

- 1: **Вход:** $x \in Q$; $h \in \mathbb{R}^d$; $\tau \in \mathbb{R}$
 - 2: Сэмплируем $i \in \overline{1, d}$ равномерно и независимо
 - 3: Считаем $\tilde{\nabla}_i f_\delta(x) = \frac{f_\delta(x + \tau e_i) - f_\delta(x - \tau e_i)}{2\tau} e_i$
 - 4: $h = h - \langle h, e_i \rangle e_i + \tilde{\nabla}_i f_\delta(x)$
 - 5: **Выход:** h
-

Алгоритм 2

- 1: **Вход:** $x \in Q$; $h, g \in \mathbb{R}^d$; $\tau \in \mathbb{R}$; $\eta \in [0, 1]$
 - 2: Сэмплируем $i \in \overline{1, d}$ равномерно и независимо
 - 3: Сэмплируем $\xi^+, \xi^- \sim \pi$ независимо (в случае ДОС $\xi^+ = \xi^-$)
 - 4: Считаем $\tilde{\nabla}_i f_\delta(x, \xi^\pm) = \frac{f_\delta(x + \tau e_i, \xi^+) - f_\delta(x - \tau e_i, \xi^-)}{2\tau} e_i$
 - 5: $\rho = h - d \cdot \langle h, e_i \rangle e_i + d \cdot \tilde{\nabla}_i f_\delta(x, \xi^\pm)$
 - 6: $h = h - \langle h, e_i \rangle e_i + \tilde{\nabla}_i f_\delta(x, \xi^\pm)$
 - 7: $g = (1 - \eta)g + \eta\rho$
 - 8: **Выход:** g, h
-

Обычный алгоритм Франка-Вульфа

1. Ограниченность множества Q :

$$\exists D > 0 : \forall x, y \in Q \hookrightarrow \|x - y\| \leq D.$$

2. Выпуклость множества Q :

$$\forall 0 \leq \alpha \leq 1, \forall x, y \in Q \hookrightarrow \alpha x + (1 - \alpha)y \in Q.$$

3. Функция $f(x)$ выпукла на множестве Q :

$$\forall x, y \in Q \hookrightarrow f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

Алгоритм 3

- 1: **Вход:** $x_0 \in Q, \gamma_k$
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $s^k = \arg \min_{s \in Q} \langle s, \nabla f(x^k) \rangle$
 - 4: $x^{k+1} = x^k + \gamma_k(s^k - x^k)$
 - 5: **end for**
 - 6: **Выход:** x^{N+1}
-

Алгоритм Франка-Вульфа с JAGUAR-d

1. Функция $f(x)$ L -гладкая на множестве Q :

$$\exists L > 0 : \forall x, y \in Q \hookrightarrow \|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|.$$

2. Шум оракула ограничен:

$$\exists \Delta > 0 : \forall x \in Q \hookrightarrow |\delta(x)|^2 \leq \Delta^2.$$

Алгоритм 4

- 1: **Вход:** $x^0 \in Q$, $h^0 = \tilde{\nabla} f_\delta(x^0)$, γ_k , τ
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $h^{k+1} = \text{JAGUAR-d}(x^k, h^k)$
 - 4: $s^k = \arg \min_{x \in Q} \langle s, h^{k+1} \rangle$
 - 5: $x^{k+1} = x^k + \gamma_k(s^k - x^k)$
 - 6: **end for**
 - 7: **Вход:** x^{N+1}
-

Сходимость алгоритма Франка-Вульфа с JAGUAR-d

Теорема (Богданов А., 2023) При шаге оптимизатора:

$$\gamma_k = \frac{4}{k + 8d},$$

получается оценка на сходимость:

$$\mathbb{E} [f(x^k) - f(x^*)] = \mathcal{O} \left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{k + 8d} + \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau} \right).$$

Следствие Пусть ε определяет точность: $\mathbb{E} [f(x^N) - f(x^*)] \leq \varepsilon$:

$$N = \mathcal{O} \left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{\varepsilon} \right),$$

$$\gamma = \mathcal{O} \left(\frac{\varepsilon}{\sqrt{d}LD} \right), \quad \Delta = \mathcal{O} \left(\frac{\varepsilon^2}{dLD^2} \right).$$

Допущения для аппроксимации JAGUAR-s

1. Функция $f(x, \xi)$ $L(\xi)$ -гладкая на множестве Q :

$$\forall x, y \in Q \hookrightarrow \|\nabla f(x, \xi) - \nabla f(y, \xi)\| \leq L(\xi) \|x - y\|.$$

2. Шум оракула ограничен:

$$\exists \Delta > 0 : \forall x \in Q \hookrightarrow \mathbb{E} [|\delta(x, \xi)|^2] \leq \Delta^2.$$

3. Второй момент градиента оракула ограничен:

$$\exists \sigma_{\nabla} \geq 0 : \forall x \in Q \hookrightarrow \mathbb{E} [\|\nabla f(x, \xi) - \nabla f(x)\|^2] \leq \sigma_{\nabla}^2.$$

4. Второй момент оракула ограничен (для ООС):

$$\exists \sigma_f \geq 0 : \forall x \in Q \hookrightarrow \mathbb{E} [|f(x, \xi) - f(x)|^2] \leq \sigma_f^2.$$

Алгоритм 5

- 1: **Вход:** $x^0 \in Q$, $h^0 = g^0 = \tilde{\nabla} f_\delta(x^0)$, γ_k , η_k , τ
 - 2: **for** $k = 0, 1, 2, \dots, N$ **do**
 - 3: $g^{k+1}, h^{k+1} = \text{JAGUAR-s}(x^k, h^k, g^k, \eta_k)$
 - 4: $s^k = \arg \min_{x \in Q} \langle s, g^{k+1} \rangle$
 - 5: $x^{k+1} = x^k + \gamma_k(s^k - x^k)$
 - 6: **end for**
 - 7: **Вход:** x^{N+1}
-

Сходимость алгоритма Франка-Вульфа с JAGUAR-s

Теорема (Богданов А., 2023) При шаге оптимизатора и шаге моментума:

$$\gamma_k = \frac{4}{k + 8d^{3/2}}, \quad \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}}$$

получается оценка на сходимость:

$$\mathbb{E} [f(x^k) - f(x^*)] = \mathcal{O} \left(\frac{\max\{LD^2 + d\sigma_f D/\tau + d\sigma_{\nabla} D, \sqrt{d}(f(x^0) - f(x^*))\}}{(k + 8d^{3/2})^{1/3}} + \sqrt{d}LD\tau + \frac{\sqrt{d}\Delta D}{\tau} \right).$$

Следствие Пусть ε определяет точность: $\mathbb{E} [f(x^N) - f(x^*)] \leq \varepsilon$:

$$N = \mathcal{O} \left(\max \left\{ \left[\frac{\max\{LD^2 + d\sigma_{\nabla} D, \sqrt{d}(f(x^0) - f(x^*))\}}{\varepsilon} \right]^3; \frac{d^{9/2}\sigma_f^3 L^3 D^6}{\varepsilon^6} \right\} \right),$$
$$\gamma = \mathcal{O} \left(\frac{\varepsilon}{\sqrt{d}LD} \right), \quad \Delta = \mathcal{O} \left(\frac{\varepsilon^2}{dLD^2} \right).$$

Постановка эксперимента

1. Модели: SVM, LogReg и Reg;
2. Множества: симплекс Δ_d , l_1 -шар и l_2 -шар;
3. Датасеты: MNIST, Mushrooms и синтетический;
4. Шум:
 - 4.1 Детерминированный: $f_\delta(x) = \text{round}(f(x), 5)$;
 - 4.2 Стохастический:


$$f_\delta(x, \xi) = f(x) + \xi^T x; \xi_i = \text{clip}(\tilde{\xi}_i, -1, 1), \tilde{\xi}_i \sim \mathcal{N}(0, 1);$$

5. Сравнение: с l_2 -сглаживанием и полной аппроксимацией
6. Метрика:


$$\text{gap}(x^k) = \max_{y \in Q} \langle \nabla f(x^k), x^k - y \rangle$$

Эксперимент для детерминированного случая


SVM on l_1 -ball
Mushrooms dataset




Reg on Δ_d
Synthetic dataset



LogReg on l_1 -ball
Mushrooms dataset




LogReg on l_2 -ball
Mushrooms dataset




Эксперимент для одноточечной обратной связи


SVM on l_2 -ball
Mushrooms dataset




SVM on Δ_d
MNIST dataset







SVM on l_2 -ball
MNIST dataset



SVM on l_1 -ball
MNIST dataset



Эксперимент для двухточечной обратной связи



Выносятся на защиту

1. Предложен робастый алгоритм аппроксимация градиента JAGUAR, использующий $\mathcal{O}(1)$ вызовов оракула на каждой итерации;
2. Вычислительные эксперименты подтвердили теоретические оценки сходимости метода в детерминированных и стохастических условиях для алгоритма Франка-Вульфа, продемонстрировав его превосходство над l_2 -сглаживанием и полной аппроксимаций.

Список работ автора по теме диплома

1. New Aspects of Black Box Conditional Gradient: Variance Reduction and One Point Feedback // Neural Information Processing Systems (на рецензировании).
2. Применение стохастической аппроксимации нулевого порядка с техникой запоминания в алгоритме Франка-Вульфа // 66-я Всероссийская научная конференция МФТИ, 2024.