Новые грани концепции черного ящика в методе условного градиента

Александр Иванович Богданов

Научный руководитель: к.ф.-м.н. Безносиков А. Н.

Московский физико-технический институт $\Phi\Pi M U$ Кафедра «Интеллектуальные системы»

Цель исследования

Цель: Ставится выпуклая задача оптимизации на ограниченном множестве с доступом только к нулевому оракулу.

Решение: Предлагается модификация JAGUAR, которая использует аппроксимацию градиента для подсчета условного градиента.

Литература

- Aryan Mokhtari, Hamed Hassani, and Amin Karbasi. Stochastic conditional gradient methods: From convex minimization to submodular maximization. The Journal of Machine Learning Research, 21(1):4232–4280, 2020.
- Ohad Shamir. An optimal algorithm for bandit and zero-order convex optimization with two-point feedback. The Journal of Machine Learning Research, 18(1):1703–1713, 2017.
- Alexander Gasnikov, Darina Dvinskikh, Pavel Dvurechensky, Eduard Gorbunov, Aleksander Beznosikov, and Alexander Lobanov. Randomized gradient-free methods in convex optimization. arXiv preprint arXiv:2211.13566, 2022.

Постановка задачи

Рассматривается две оптимизационные задачи:

Нестохастическая

$$\min_{x \in Q} f(x)$$

Доступ только к $f_\delta(x) := f(x) + \delta(x)$, где $\delta(x)$ - шум.

Стохастическая

$$\min_{x \in Q} f(x) := \mathbb{E}_{\xi} [f(x, \xi)],$$

Доступ только к $f_{\delta}(x,\xi) := f(x,\xi) + \delta(x,\xi)$, где $\delta(x,\xi)$ - шум.

 $Q\subseteq \mathbb{R}^d$ - произвольное выпуклое ограниченное множество, f(x) - выпуклая на Q функция.

Разностная схема, которая будет использоваться в алгоритме:

$$\widetilde{\nabla}_i f_{\delta}(x) := \frac{f_{\delta}(x + \gamma e_i) - f_{\delta}(x - \gamma e_i)}{2\gamma} e_i,$$

где e_i - i-ый базисный вектор, γ - параметр сглаживания.

Algorithm JAGUAR. Нестохастический случай

- 1: Вход: $x, h \in \mathbb{R}^d$
- 2: Сэмплируем $i\in\overline{1,d}$ независимо и равномерно
- 3: Считаем $\widetilde{
 abla}_i f_\delta(x) = rac{f_\delta(x+\gamma e_i) f_\delta(x-\gamma e_i)}{2\gamma} e_i$
- 4: $g = g \langle h, e_i \rangle e_i + \widetilde{\nabla}_i f_{\delta}(x)$
- 5: **Выход:** *g*

Франк-Вульф с JAGUAR в нестохастическом случае

Algorithm ФВ с JAGUAR в нестохастическом случае

```
1: Вход: x_0 \in Q, g^0 = \widetilde{\nabla} f(x^0)

2: for k = 0, 1, 2, ..., N do

3: g^{k+1} = \mathsf{JAGUAR}\left(x^k, g^k\right)

4: s^k = \operatorname*{arg\ min}\left\{\left\langle s, g^{k+1}\right\rangle\right\}

5: x^{k+1} = x^k + \gamma_k(s^k - x^k)

6: end for

7: Выход: x^{N+1}
```

Допущения:

1. Функция f(x) *L*-гладкая на множестве Q, то есть:

$$\forall x, y \in Q \hookrightarrow \|\nabla f(x) - \nabla f(y)\| \le L \|x - y\|$$
.

2. Ограниченность оракульного шума:

$$\exists \Delta > 0 : \ \forall x \in Q \hookrightarrow |\delta(x)|^2 \leq \Delta^2.$$

3. Ограниченность:

$$||x-y||^2 \le D^2,$$

для любых $x, y \in Q$.

Теорема При шаге оптимизатора:

$$\gamma_k = \frac{4}{k + 8d}$$

получается следующее:

$$\mathbb{E}\left[\left\|h^{k} - \nabla f(x^{k})\right\|^{2}\right] = \mathcal{O}\left(dL^{2}\gamma^{2} + \frac{d\Delta^{2}}{\gamma^{2}} + \frac{\max\{d^{2}L^{2}D^{2}, \left\|h^{0} - \nabla f(x^{0})\right\|^{2} \cdot d^{2}\}}{(k+d)^{2}}\right).$$

Если $h_0 = \widetilde{\nabla} f_\delta(x^0)$, то можно упростить:

$$\mathbb{E}\left[\left\|h^{k}-\nabla f(x^{k})\right\|^{2}\right]=\mathcal{O}\left(dL^{2}\gamma^{2}+\frac{d\Delta^{2}}{\gamma^{2}}+\frac{d^{2}L^{2}D^{2}}{(k+8d)^{2}}\right).$$

Франк-Вульф с JAGUAR в нестохастическом случае

Теорема При шаге оптимизатора:

$$\gamma_k = \frac{4}{k + 8d}$$

получается следующее:

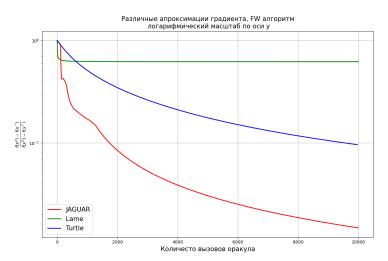
$$\mathbb{E}\left[f(x^N) - f(x^*)\right] = \mathcal{O}\left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{N + 8d} + \sqrt{d}LD\gamma + \frac{\sqrt{d}\Delta D}{\gamma}\right).$$

Следствие Пусть ε определяет точность, то есть $\mathbb{E}\left[f(x^N) - f(x^*)\right] \leq \varepsilon$. Тогда:

$$\begin{split} N &= \mathcal{O}\left(\frac{d \max\{LD^2, f(x^0) - f(x^*)\}}{\varepsilon}\right), \\ \gamma &= \mathcal{O}\left(\frac{\varepsilon}{\sqrt{d}LD}\right), \quad \Delta = \mathcal{O}\left(\frac{\varepsilon^2}{dLD^2}\right). \end{split}$$

Эксперимет

Эксперимент проводился на тренировочном датасете "mushrooms".



Разностные схемы, которые будут использоваться в алгоритме:

▶ Двухточечная обратная связь:

$$\widetilde{\nabla}_i f_{\delta}(x,\xi) := \frac{f_{\delta}(x+\gamma e_i,\xi) - f_{\delta}(x-\gamma e_i,\xi)}{2\gamma} e_i,$$

Одноточечная обратная связь:

$$\widetilde{\nabla}_i f_{\delta}(x,\xi^+,\xi^-) := \frac{f_{\delta}(x+\gamma e_i,\xi^+) - f_{\delta}(x-\gamma e_i,\xi^-)}{2\gamma} e_i,$$

где e_i - i-ый базисный вектор, γ - параметр сглаживания.

Algorithm JAGUAR. Стохастический случай

- 1: Вход: $x, h, g \in \mathbb{R}^d$, $0 \le \eta \le 1$
- 2: Сэмплируем $i \in \overline{1,d}$ независимо и равномерно
- 3: Сэмплируем 2 реализации ξ : ξ^+ и ξ^- независимо (в случае одноточечной обратной связи $\xi^+ = \xi^-$)

4: Считаем
$$\widetilde{\nabla}_i f_\delta(x,\xi^+,\xi^-) = \frac{f_\delta(x+\gamma e_i,\xi^+) - f_\delta(x-\gamma e_i,\xi^-)}{2\gamma} e_i$$

5:
$$h = h - \langle h, e_i \rangle e_i + \widetilde{\nabla}_i f_{\delta}(x, \xi^+, \xi^-)$$

6:
$$\rho = h - d \cdot \langle h, e_i \rangle e_i + d \cdot \nabla_i f_\delta(x, \xi^+, \xi^-)$$

7:
$$g = (1 - \eta)g + \eta \rho$$

8: Выход: h и g

Допущения:

1. Функция $f(x,\xi)$ $L(\xi)$ -гладкая на множестве Q, то есть:

$$\forall x, y \in Q \hookrightarrow \|\nabla f(x, \xi) - \nabla f(y, \xi)\| \le L(\xi) \|x - y\|.$$

2. Ограниченность оракульного шума:

$$\exists \Delta > 0: \ \forall x \in Q \hookrightarrow \mathbb{E}\left[|\delta(x,\xi)|^2\right] \leq \Delta^2$$

3. Ограниченность второго момента градиента:

$$\exists \sigma_{\nabla}^2 : \mathbb{E}\left[\left\|\nabla f(x,\xi) - \nabla f(x)\right\|^2\right] \leq \sigma_{\nabla}^2$$

4. Ограниченность второго момента градиента:

$$\exists \sigma_f^2 : \mathbb{E}\left[\left|f(x,\xi) - f(x)\right|^2\right] \leq \sigma_f^2$$

Франк-Вульф с JAGUAR в стохастическом случае

Algorithm ФВ с JAGUAR в стохастическом случае

```
1: Вход: x_0 \in Q, h^0 = g^0 = \widetilde{\nabla} f_\delta(x^0, \xi_1^+, ...., \xi_d^-), \{\eta_k\}_{k=0}^N \subset [0; 1]
2: for k = 0, 1, 2, ..., N do
3: h^{k+1}, g^{k+1} = \mathsf{JAGUAR}(x^k, h^k, g^k, \eta_k)
4: s^k = \operatorname*{arg\,min}_{x \in Q} \{\langle s, g^{k+1} \rangle\}
5: x^{k+1} = x^k + \gamma_k (s^k - x^k)
6: end for
7: Выход: x^{N+1}
```

Теорема При шаге оптимизатора и шаге моментума:

$$\gamma_k = \frac{4}{k + 8d^{3/2}}, \quad \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}}$$

получается следующее:

$$\mathbb{E}\left[\left\|g^{k} - \nabla f(x^{k})\right\|^{2}\right] = \mathcal{O}\left(\frac{d^{4}\left\|h^{0} - \nabla f(x^{0})\right\|^{2}}{(k + 8d^{3/2})^{8/3}} + dL^{2}\gamma^{2} + \frac{d\Delta^{2}}{\gamma^{2}}\right) + \frac{L^{2}D^{2} + \max\{d^{2}\sigma_{f}^{2}/\gamma^{2} + d^{2}\sigma_{\nabla}^{2}, d\left\|g^{0} - \nabla f(x^{0})\right\|^{2}\}}{(k + 8d^{3/2})^{2/3}}\right)$$

Если $h^0=g^0=\widetilde{\nabla}f_\delta(x^0,\xi_1^+,\xi_1^-,...,\xi_d^+,\xi_d^-)$, то можно упростить:

$$\mathbb{E}\left[\left\|g^{k}-\nabla f(x^{k})\right\|^{2}\right]=\mathcal{O}\left(\frac{L^{2}D^{2}+d^{2}\sigma_{f}^{2}/\gamma^{2}+d^{2}\sigma_{\nabla}^{2}}{(k+8d^{3/2})^{2/3}}+dL^{2}\gamma^{2}+\frac{d\Delta^{2}}{\gamma^{2}}\right)$$

Франк-Вульф с JAGUAR в стохастическом случае

Теорема При шаге оптимизатора и шаге моментума:

$$\gamma_k = \frac{4}{k + 8d^{3/2}}, \quad \eta_k = \frac{4}{(k + 8d^{3/2})^{2/3}}$$

получается следующее:

$$\mathbb{E}\left[f(x^{N}) - f(x^{*})\right] = \mathcal{O}\left(\frac{LD^{2} + d\sigma_{f}D/\gamma + d\sigma_{\nabla}D + \sqrt{d}(f(x^{0}) - f(x^{*}))}{(N + 8d^{3/2})^{1/3}} + \sqrt{d}LD\gamma + \frac{\sqrt{d}\Delta D}{\gamma}\right)$$

Следствие Пусть ε определяет точность, то есть $\mathbb{E}\left[f(x^N) - f(x^*)\right] \leq \varepsilon$. Тогда:

$$N = \mathcal{O}\left(\max\left\{\left[\frac{LD^2 + d\sigma_{\nabla}D + \sqrt{d}(f(x^0) - f(x^*))}{\varepsilon}\right]^3, \frac{d^{9/2}\sigma_f^3L^3D^6}{\varepsilon^6}\right\}\right),$$

$$\gamma = \mathcal{O}\left(\frac{\varepsilon}{\sqrt{d}LD}\right), \quad \Delta = \mathcal{O}\left(\frac{\varepsilon^2}{dLD^2}\right).$$

Вывод

Для задачи выпуклой задачи оптимизации на ограниченном множестве с доступом только к нулевому оракулу предложена и исследована модификация JAGUAR для Франка-Вульфа. Получены теоретические оценки сходимости для нестохастического и стохастического случаев.

Дальнейшая работа

- Провести эксперименты на различных множествах, датасетах, функциях;
- Возможно, рассмотреть другие методы, например, градиентный спуск.